

玩具：泛函 $J[y]$ ($y = y(x)$)，变分 $\frac{\delta J}{\delta y}$ ，熵 $H[p] = -\int p \log p dy$ ，KL散度，Bandit.....

edit time: 2026-05-15 20:12:10

目录

Regret

Hoeffding：随着n增大，不喜欢的概率是指数级下降的 (e^n)。

Bandit：最小化累积Regret

- $\epsilon - Greedy$ ，Regret线性增加，如果逐渐降低 ϵ 的话不好做，是很技术的问题
- UCB，对于不确定性乐观，无悔（平均界 $\rightarrow 0$ ，最差界 $\rightarrow \sqrt{T}$ ）
- Thompson Sampling（与UCB同阶）
最优学习：已经找到一个最大值之后，通过积极地尝试其他选项，降低其他选项可能成为最大值的概率
- KG（Knowledge Gradient）

泛函

Euler-Lagrange方程

最大熵原理

KL散度和变分推断：用q 编码来自p 的数据，平均多花多少bits

最小化KL散度等价于最大化ELBO

从最优控制到Bellman方程

exercise1-exercise10

变分法与最优控制知识部分

Euler-Lagrange方程：设函数 $y(x)$ ，泛函

$$J[y] = \int F(y, y', x) dx$$

取极值时必有

$$\frac{\partial F}{\partial y} - \frac{d}{dx} \frac{\partial F}{\partial y'} = 0$$

最大熵原理：选择满足约束的熵最大的分布。

$$\max_p H[p] = - \int p(x) \log p(x) dx$$

subject to 约束条件

另外，熵的形式是 $-\int p \log p dx$ ，也可以把 p 看作概率密度，写作 $H[p] = -\mathbb{E}_p[\log p]$ ，即 p 的熵等价于负的 $\log p$ 关于 p 的期望。

关于泛函求变分，有关键公式：

$$\frac{\partial}{\partial p(x)} \int f(p(y)) dy = f'(p(x))$$

这个公式形式有点像变上限的积分求导公式。可以推得以下二级结论：

$$\frac{\partial}{\partial p(x)} \int p(y) dy = 1$$

$$\frac{\partial}{\partial p(x)} \int p \log p dy = \log p + 1$$

以及对指数分布，有

$$H[p] = \ln \mu + 1$$

无约束时，均匀分布熵最大。

给定均值时，指数分布熵最大。

给定均值和方差时，高斯分布熵最大。

一般地，最大熵分布是指数族分布的形式。

KL散度：用 q 编码来自 p 的数据，平均多花多少bits。

$$D_{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx = \mathbb{E}_p[\log \frac{p(x)}{q(x)}]$$

注意KL散度具有不对称性（见eg3），被使用的写在后面和分母处。

变分推断是希望找简单分布 $q(z)$ 近似使得 $q(z) \approx p(z|x)$ ，从而使得贝叶斯推断问题可求。于是考虑使用 $D_{KL}(p||q)$ 或者 $D_{KL}(q||p)$ ，前者在计算上不可行（同贝叶斯推断），无奈之下只能使用后者。

容易推导得到，（当然， $\log p(x)$ 也可以写作 $E_q[\log q(z)]$ ）

$$\log p(x) = D_{KL}(q||p) + \int q \log \frac{p(x, z)}{q(z)} dz = D_{KL}(q||p) + ELBO(q)$$

考虑到 $D_{KL}(q||p) \geq 0$ ，有 $\log p(x) \geq ELBO(q)$ 。故称 $ELBO$ 为evidence lower bound。
最小化KL等价于最大化ELBO，即给定 q ，最大化 $\log p(x, z)$ 和 $\log q(z)$ 的期望之差。

$$ELBO(q) = \mathbb{E}_q[\log p(x, z)] - \mathbb{E}_q[\log q(z)]$$

当然，也可以写成下述两种等价形式：

(联合对数似然的期望 + q的熵；重构项 - 正则项)

$$ELBO(q) = \mathbb{E}_q[\log p(x, z)] + H[q]$$

$$ELBO(q) = \mathbb{E}_q[\log p(x|z)] - D_{KL}(q(z)||p(z))$$

变分推断就是为了通过最大化下界ELBO，来间接优化难以直接计算的对数证据 $\log p(x)$ 。

LQR问题，我们从一个数值例子反着来。

LQR的线性动力学： $\dot{x} = Ax + Bu$

LQR的二次代价：

$$J = \frac{1}{2}x(T)^T Q_f x(T) + \frac{1}{2} \int_0^T (x^T Q x + u^T R u) dt$$

其中 $f(x, u) = Ax + Bu$ ， $L(x, u) = x^T Q x + u^T R u$ 。

数值例子：

$\dot{x} = x + u$, $J = \frac{1}{2}x(T)^2 + \frac{1}{2} \int_0^T (x^2 + u^2) dt$ ，目标是控制 x 到 0，同时不用太大的 u 。

对于该例子， $Q = R = Q_f = A = B = 1$ ，

Ricacci方程为（LQR的Ricacci方程形式为 $-\dot{P} = Q + A^T P + PA - PBR^{-1}B^T P$ ）

$$-\dot{P} = 1 + 2P - P^2$$

稳态令 $\dot{P} = 0$ 有 $P = 1 + \sqrt{2}$ ，

最优控制 $u^* = -Px \approx -2.414x$ （LQR的最优控制为 $u^* = -R^{-1}B^T Px$ ），

闭环动力学 $\dot{x} \approx -1.414x$ ，稳定，极点在 -1.414 。

如果不加控制（令 $u = 0$ ），则有 $\dot{x} = x$ ，这一一阶微分形式使得指数增长，不稳定。

接下来反过来看怎么推出LQR的Ricacci方程。

HJB方程（Hamilton-Jacobi-Bellman方程）：

$$-\frac{\partial V}{\partial t} = \min_u [L(x, u, t) + \nabla_x V \cdot f(x, u, t)]$$

猜测LQR的 $V(x, t) = \frac{1}{2}x^T P(t)x$ ，

则有 $\nabla_x V = Px$ ， $\frac{\partial V}{\partial t} = \frac{1}{2}x^T \dot{P}x$ ，

代入HJB方程，将HJB方程视为 u 的函数，最小化 u 得最优控制

$$u^* = -R^{-1}B^T Px$$

这是一个对 x 的线性反馈。将其代回HJB方程就得到了LQR的Ricacci方程

$$-\dot{P} = Q + A^T P + PA - PBR^{-1}B^T P$$

从而前述的数值例子是从HJB这个根本的方程推得的。（HJB由Bellman最优性原理推得）

在线优化与Regret框架知识部分

$$\text{Regret}_T = \underbrace{\sum_{t=1}^T \ell_t(x_t)}_{\text{你的总损失}} - \underbrace{\min_{x \in \mathcal{X}} \sum_{t=1}^T \ell_t(x)}_{\text{最佳固定策略}}$$

注意，总损失是由选择 $x_1, x_2, \dots, x_T$ 得到的，
而最佳固定策略的选择在各轮都是相同固定的最佳选择 x 。
这意味着，我们的动态切换可能会比最佳固定策略好，但也可能因为动态切换而损失更高。

Regret的量级分为 $O(T)$ ， $O(\sqrt{T})$ 和 $O(\log T)$ ，其中 $O(\sqrt{T})$ 开始是平均后悔趋于0的（ $T \rightarrow \infty, O(\frac{\sqrt{T}}{T}) \rightarrow 0$ ），符合我们的需求。 $O(\log T)$ 也可能达到，但需要更强的假设。

MWU：给每个专家打分，表现差的惩罚，惩罚是乘性的（指数惩罚）。

- 1: 每个专家初始权重 $w_i = 1$
- 2: 选一个学习率 η (比如 0.1)
- 3: for 每一轮 $t = 1, 2, \dots, T$ do
- 4: 计算概率： $p_i = \frac{w_i}{\sum_j w_j}$ （权重归一化）
- 5: 按概率随机选一个专家
- 6: 看到所有专家的损失 $\ell_t(i)$ (0 到 1 之间)
- 7: 乘法更新： $w_i \leftarrow w_i \times (1 - \eta \cdot \ell_t(i))$
- 8: end for

Hoeffding不等式：采样n次，偏差大的概率指数级衰减。采样越多，估计越准。

定理 4.1 (Hoeffding 不等式). n 个独立样本 $X_i \in [0, 1]$ ，样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ ，真实均值

μ ，则：

$$P(|\bar{X} - \mu| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$$

即样本均值偏移真实均值，偏差更大的概率随着样本数 n 指数级衰减。

比如抛硬币，想知道估计误差超过 $\epsilon = 0.1$ 的概率，

$n = 100$ 时， $p(|\hat{p} - p| \geq 0.1) \leq 0.27$ ，即还有27%的概率估计误差超过0.1。

$n = 500$ 时， $p(|\hat{p} - p| \geq 0.1) \leq 0.00009$ ，即还有0.009%的概率估计误差超过0.1，基本不可能。

如果想要95%的把握误差不超过 ϵ ，则 ϵ 应通过以下式子求得：

$$2e^{-2n\epsilon^2} = 0.05$$

可见，置信区间宽度正比于 $1/\sqrt{n}$ 。

这意味着，想把误差减半，需要4倍样本；想把误差减到十分之一，需要100倍的样本。

这与Regret为 $O(\sqrt{T})$ 不谋而合：我们获取信息的速度就是 $\sqrt{T}$ 。

Bandit：有多台老虎机，各自收益不同。每次选一台拉，拉 T 次，总收益最大。

（平衡探索与利用）

ϵ -Greedy：

以 $1 - \epsilon$ 的概率选目前估计最好的，以 ϵ 概率随机选一个。

UCB：

$$UCB_a(t) = \hat{\mu}_a + \sqrt{\frac{2 \ln t}{n_a}}$$

第二项 $\sqrt{\frac{2 \ln t}{n_a}}$ 是探索奖励，因为拉的次数较少时，该项较大，奖励拉该臂更多次。

Thompson Sampling：将每个臂先验置为 $Beta(1,1)$ ，采样各个分布，选取最大值，看结果如何，并更新相应臂的分布。

1: 每台机器初始化： $\alpha_a = 1, \beta_a = 1$ (先验置为 $Beta(1,1)$)

2: for 每一轮 do

3: 对每台机器 a ，从 $Beta(\alpha_a, \beta_a)$ 采样一个 θ_a

4: 选择 θ 最大的机器

5: 观察结果：赢则 $\alpha_a \leftarrow \alpha_a + 1$ ，输则 $\beta_a \leftarrow \beta_a + 1$

6: end for

最优学习：最大化最终选择的 μ 值。“更激进的探索最优”

Knowledge Gradient (KG)：应选择KG值最大的臂进行探索（“一次实验改进的决策”）。

$$KG(a) = \tilde{\sigma}_a \cdot f(z)$$

其中有效标准差为后验标准差和噪声标准差求得的

$$\tilde{\sigma}_a = \frac{\sigma_a^2}{\sqrt{\sigma_a^2 + \sigma_\epsilon^2}}$$

z 为当前均值和“对手最佳” $\nu_{-a} = \max_{a' \neq a} \hat{\mu}_{a'}$ 的差值绝对值再归一化

$$z = \frac{|\hat{\mu}_a - \nu_{-a}|}{\tilde{\sigma}_a}$$

f 为标准正态分布期望

$$f(z) = z\Phi(z) + \phi(z), z \geq 0$$

eg1. Euler-Lagrange方程基础

$$F = (y')^2 + y^2$$

(a) Euler-Lagrange方程有

$$2y - \frac{d(2y')}{dx} = 0$$

即

$$y'' - y = 0$$

(b) 二阶常微分方程。

$$r^2 - 1 = 0$$

解得 $r_1 = 1, r_2 = -1$ 。

故有

$$y(x) = C_1 e^x + C_2 e^{-x}$$

代入 $y(0) = 0, y(1) = 1$ 得

$$C_1 = \frac{1}{e - e^{-1}}, C_2 = -C_1, y(x) = \frac{e^x - e^{-x}}{e - e^{-1}}$$

又有 $e^x - e^{-x} = 2 \sinh(x)$ ，故有我们要找的满足Euler-Lagrange方程的特定的极值函数

$$y^*(x) = y(x) = \frac{\sinh x}{\sinh 1}$$

(c) 由(b)得

$$y'(x) = \frac{\cosh x}{\sinh 1}$$

注意到

$$\frac{d}{dx}(yy') = (y')^2 + yy''$$

又有 $y'' = y$ ，则有

$$\frac{d}{dx}(yy') = y^2 + (y')^2 = F$$

故

$$J[y] = \int_0^1 F dx = \int_0^1 \frac{d}{dx}(yy') dx$$

$$J[y] = yy'|_0^1$$

考虑到 $\sinh 0 = 0, \cosh 0 = 1$ ，

当 $x = 0$ 时， $y'(0) = \frac{1}{\sinh 1}$ ， $y(0) = 0$ ， $yy' = 0$ ，

当 $x = 1$ 时， $y'(1) = \frac{\cosh 1}{\sinh 1}$ ， $y(1) = 1$ ， $yy' = \frac{\cosh 1}{\sinh 1}$ 。

故有泛函最小值

$$J^* = \frac{\cosh 1}{\sinh 1} = \coth 1 \approx 1.313$$

(d) 当 $y = x$ 时， $y' = 1$ 。

$$J[y] = \int_0^1 (1 + x^2) dx = (x + \frac{1}{3}x^3)|_0^1 = \frac{4}{3} > J^*$$

即不满足E-L方程的试探函数 $y = x$ 的 J 值大于 J^* ，不为极值。

eg2. 约束下的最大熵分布

设 $x \in [0, \infty)$ ，已知 $\mathbb{E}[x] = 3$ 。

(a) 由 $\mathbb{E}[x] = 3$ 可得问题约束条件为归一化和均值约束

$$\int_0^\infty p(x) dx = 1$$

$$\int_0^{\infty} xp(x)dx = 3$$

使用Lagrange乘子法求最大熵，设

$$L = - \int p \log p dx - \lambda_0 \left(\int p(x) dx - 1 \right) - \lambda_1 \left(\int xp(x) dx - 3 \right)$$

变分有

$$\frac{\partial L}{\partial p} = -\log p - 1 - \lambda_0 - \lambda_1 x = 0$$

(b) 解出最大熵分布 $p^*(x)$ 的解析形式有

$$p = e^{-1-\lambda_0-\lambda_1 x} = Ce^{-\lambda_1 x}$$

(c) 满足指数分布的形式： $p(x) = \frac{1}{\mu} e^{-x/\mu}$ 。

故给定 $\mu = 3$ 则有

$$p(x) = \frac{1}{3} e^{-\frac{x}{3}}$$

(d)

$$\ln p = \ln \frac{1}{3} - \frac{x}{3} = -\ln 3 - \frac{x}{3}$$

微分熵 $H[p^*]$ 为

$$H[p^*] = - \int_0^{\infty} p \ln p dx$$

暂时不代入 $\mu = 3$ ，考虑指数分布的微分熵的一般情况。有

$$H[p^*] = - \int p \left(-\ln \mu - \frac{x}{\mu} \right) dx = \ln \mu + \frac{1}{\mu} \int p x dx = \ln \mu + \frac{1}{\mu} \cdot \mu = \ln \mu + 1$$

故有本问题的 $H = 1 + \ln 3 \approx 2.099$ nats。

eg3. 高斯分布之间的KL散度

(a)

$$D_{KL}(N(\mu_1, \sigma_1^2) || N(\mu_2, \sigma_2^2)) = \int p_1 \log \frac{p_1}{p_2} dx$$

解析解为

$$D_{KL}(N_1||N_2) = \log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$$

(b)

代入 $\mu_p = 0, \sigma_p = 1, \mu_q = 1, \sigma_q = 2$ 得

$$D_{KL}(p||q) = \ln 2 + 0.25 - 0.5 \approx 0.443$$

(c)

$$D_{KL}(q||p) = -\ln 2 + 2.5 - 0.5 \approx 1.307$$

(d)

$$D_{KL}(p||q) < D_{KL}(q||p)$$

$D_{KL}(p||q)$ 鼓励 q 覆盖 p 的高概率区域 (zero-forcing, q 在 p 概率大的地方也要大, 可以忽略 p 的尾部),

而 $D_{KL}(q||p)$ 鼓励 q 平均拟合 p (mean-seeking, q 在 p 概率小的地方也要小, 否则会受很大惩罚, 从而让 q 尽量覆盖 p 的全部支撑集)。

eg4. VAE的KL正则项

(a)

$$D_{KL}(q||p) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2)$$

(b) $d = 3$, 有三项。

$$\begin{aligned} D_{KL}(q||p) &= \frac{1}{2} [(0.5^2 + 0.5 - 1 - \log 0.5) + ((-0.5)^2 + 1.5 - 1 - \log 1.5) + (1^2 + 0.4 - 1 - \log 0.4)] \\ &= \frac{1}{2} [0.4431471806 + 0.3445348919 + 1.093147181] \end{aligned}$$

第一个分量约为 0.222, 第二个分量约为 0.172, 第三个分量约为 0.658。

(c)

$$D_{KL}(q||p) \approx 0.222 + 0.172 + 0.658 = 1.052$$

(d)

第三个分量 ($\mu = 1, \sigma^2 = 0.4$) 贡献最大。因为它均值偏离 $(0, 1)$ 程度最大 (过大), σ^2 偏移的程度也较大 (过小), KL散度对均值和方差的偏移均有正惩罚。

eg5. LQR与代数Riccati方程

(a)

$$-\dot{P} = Q + A^T P + P A - P B R^{-1} B^T P$$

代入 $A = -1, B = 2, Q = 8, R = 2$ 得

$$-\dot{P} = 8 - 2P - 2P^2$$

令 $\dot{P} = 0$ 得

$$P^2 + P - 4 = 0$$

(b)

$$P_1 = \frac{-1 + \sqrt{17}}{2}, P_2 = \frac{-1 - \sqrt{17}}{2}$$

稳态正解 $P_1 \approx 1.562$ 。

(c)

$$u^* = -R^{-1} B^T P x = -P x$$

故反馈增益 $K = -P_1 = -1.562$ ， $u^* = -1.562x$ 。

(d)

$$\dot{x} = -x + 2u = -x - 2 \times 1.562x = -4.124x$$

实部为负，系统稳定。

(e)

原系统 $\dot{x} = -x$ 本就稳定，闭环极点把收敛速度提速了 4.124 倍。

eg6. MWU手算三轮

(a) 每轮概率分布与期望损失

第一轮

$$p^{(1)} = (1/3, 1/3, 1/3)$$

$$L_1 = 1/3 \times 0.5 + 1/3 \times 0.2 + 1/3 \times 0.8 = 0.5$$

$$w_i^{(2)} = w_i^{(1)}(1 - \eta l_1(i))$$

则有

$$w^{(2)} = (1 \times (1 - 0.4 \times 0.5), 1 \times (1 - 0.4 \times 0.2), 1 \times (1 - 0.4 \times 0.8)) = (0.8, 0.92, 0.68)$$

第二轮 $0.8 + 0.92 + 0.68 = 2.4$

$$p^{(2)} = (0.8/2.4, 0.92/2.4, 0.68/2.4)$$

$$L_2 = 0.8/2.4 \times 0.3 + 0.92/2.4 \times 0.7 + 0.68/2.4 \times 0.4 \approx 0.482$$

$$w^{(3)} = (0.8 \times (1 - 0.4 \times 0.3), 0.92 \times (1 - 0.4 \times 0.7), 0.68 \times (1 - 0.4 \times 0.4))$$

$$w^{(3)} = (0.704, 0.6624, 0.5712)$$

第三轮 $0.704 + 0.6624 + 0.5712 = 1.9376$

$$p^{(3)} \approx (0.3633, 0.3419, 0.2948)$$

$$L_3 \approx 0.3501$$

综上有：（以下均为约数）

$$p^{(1)} = (0.3333, 0.3333, 0.3333), L_1 = 0.5$$

$$p^{(2)} = (0.3333, 0.3833, 0.2833), L_2 = 0.4816$$

$$p^{(3)} = (0.3633, 0.3419, 0.2948), L_3 = 0.3501$$

(b) 每轮更新后的权重

$$w^{(2)} = (0.8, 0.92, 0.68)$$

$$w^{(3)} = (0.704, 0.6624, 0.5712)$$

$$w^{(4)} = (0.53504, 0.582912, 0.548352)$$

(c) 总期望损失

$$\sum_{t=1}^3 L_t = 0.5 + 0.4816 + 0.3501 = 1.3317$$

(d) 最优固定专家：

固定专家1总损失 $0.5 + 0.3 + 0.6 = 1.4$

固定专家2总损失 $0.2 + 0.7 + 0.3 = 1.2$

固定专家3总损失 $0.8 + 0.4 + 0.1 = 1.3$

故最优固定专家 $i^* = 2$ ，其总损失为 1.2。

(e)

Regret为 $1.3317 - 1.2 = 0.1317$ 。

MWU的理论上限为

$$\frac{\ln N}{\eta} + \eta T = \frac{\ln 3}{0.4} + 0.4 \times 3 \approx 3.9465$$

实际Regret远小于上界。

eg7. Hoeffding不等式与样本量

(a) 要求95%把握下误差不超过 ϵ , 则最少样本量 n 关于 ϵ 的表达式
令

$$2e^{-2n\epsilon^2} = 0.05$$

有

$$n = -\frac{\ln 0.025}{2\epsilon^2}$$

(b) 当 $\epsilon = 0.02$ 时,

$$n = -\frac{\ln 0.025}{2 \times 0.02^2} = 4611.099318$$

95%把握下误差不超过 0.02 , 至少需要 4612 个样本。

(c) 当 $\epsilon = 0.01$ 时,

$$n = -\frac{\ln 0.025}{2 \times 0.01^2} = 18444.39727$$

95%把握下误差不超过 0.01 , 至少需要 18445 个样本。这是 (b) 的约4倍。 ϵ 减半, $1/\epsilon^2$ 变为原来的4倍, 与样本量的变化相同。即所需的样本量正比于 $1/\epsilon^2$ 。

(d) 取 $\epsilon = 0.05$,

$$P(|\bar{X} - p| \geq 0.05) \leq 2 \cdot e^{-2 \times 200 \times 0.05^2} = 2e^{-1} \approx 0.736$$

则做200次实验, 误差小于等于0.05的把握 (概率下界) 是 0.264 。

eg8. UCB决策

(a)

$$UCB_a(t) = \hat{\mu}_a + \sqrt{\frac{2 \ln t}{n_a}}$$

第二项 $\sqrt{\frac{2 \ln t}{n_a}}$ 是探索奖励, 因为拉的次数较少时, 该项较大, 奖励拉该臂更多次。

(b)

$$UCB_1(14) = 0.4 + \sqrt{\frac{2 \ln 14}{5}} \approx 1.427$$

$$UCB_2(14) = 0.6 + \sqrt{\frac{2 \ln 14}{3}} \approx 1.927$$

$$UCB_3(14) = 0.5 + \sqrt{\frac{2 \ln 14}{2}} \approx 2.124$$

$$UCB_4(14) = 0.55 + \sqrt{\frac{2 \ln 14}{4}} \approx 1.699$$

(c)

第15轮的选择是arm 3。

因为要充分探索，而arm 3被拉的次数较少（仅2次），比经验均值最大的arm 2要少。

(d)

$$Regret_T \leq \frac{8 \ln 10000}{0.3} + \frac{8 \ln 10000}{0.2} + \frac{8 \ln 10000}{0.1} \approx 1350.85$$

eg9. Thompson Sampling

两个伯努利臂，先验为 $Beta(1, 1)$ ，

观测到arm A有8次成功、2次失败；arm B有3次成功、7次失败。

(a)

arm A的后验分布为 $Beta(9, 3)$ ，arm B的后验分布为 $Beta(4, 8)$ 。

arm A:

均值为 $9/(9+3)=0.75$ ，

标准差为 $\sqrt{(9*3/((9+3)^2*(9+3+1)))}=\sqrt{(27/(144*13))}\approx\sqrt{0.0144}=0.12$ 。

arm B:

均值为 $4/(4+8)=0.3333333333$ ，

标准差为 $\sqrt{(4*8/((4+8)^2*(4+8+1)))}=\sqrt{(32/(144*13))}\approx\sqrt{0.017094}\approx 0.13$ 。

(b)

假设 $\theta_A \sim N(\mu_1, \sigma_1^2)$ ， $\theta_B \sim N(\mu_2, \sigma_2^2)$ 。则

$$\theta_A - \theta_B \sim N(\mu_1 - \mu_2, \sigma_A^2 + \sigma_B^2)$$

$$\mu_A - \mu_B = 0.75 - 0.3333 = 0.4167$$

$$\sigma_A^2 + \sigma_B^2 = 0.0144 + 0.0171 = 0.0315$$

$$\sqrt{\sigma_A^2 + \sigma_B^2} = \sqrt{0.0315} \approx 0.1775$$

$$Pr(\theta_A > \theta_B) = Pr(\theta_A - \theta_B > 0) = \Phi\left(\frac{0.4167}{0.1775}\right) = \Phi(2.348)$$

给出的标准正态值有 $\Phi(2.34) \approx 0.990$ ，可以近似所求也为 0.990。

(c)

$$\alpha'_A = 10, \beta'_A = 3, \mu'_A = \frac{10}{13} \approx 0.7692, \sigma'_A \approx 0.1126$$

Arm B不变, 仍为 $\mu_b \approx 0.3333, \sigma_B = 0.1307$ 。

故

$$\mu'_A - \mu_B \approx 0.4359, \sqrt{\sigma'^2_A + \sigma^2_B} \approx 0.1725, z = \frac{0.4359}{0.1725} \approx 2.527$$

$$Pr(\theta_A > \theta_B) \approx \Phi(2.527) \approx 0.994$$

新观测后, 概率从0.991提升到约0.994, 即选择arm A的信心更强。

(d)

差距不变但样本量增加时, 后验分布更集中, $Pr(\theta_A > \theta_B)$ 会增大。

eg10. Knowledge Gradient与最优学习

(a)

$$\tilde{\sigma}_1 = \frac{\sigma_1^2}{\sqrt{\sigma_1^2 + \sigma_\epsilon^2}} = \frac{0.05^2}{\sqrt{0.05^2 + 0.1^2}} = 0.02236$$

$$\nu_{-1} = \max\{0.65, 0.5, 0.68\} = 0.68$$

$$\tilde{\sigma}_2 = \frac{\sigma_2^2}{\sqrt{\sigma_2^2 + \sigma_\epsilon^2}} = \frac{0.2^2}{\sqrt{0.2^2 + 0.1^2}} = 0.17889$$

$$\nu_{-2} = \max\{0.7, 0.5, 0.68\} = 0.7$$

同理有 $\tilde{\sigma}_3 = 0.28461$, $\nu_{-3} = 0.7$, $\tilde{\sigma}_4 = 0.07071$, $\nu_{-4} = 0.7$ 。

(b)

对于Arm 1,

$$z_0 = \frac{0.02}{0.02236} \approx 0.8944$$

对于Arm 2,

$$z_0 = \frac{0.05}{0.17889} \approx 0.2795$$

对于Arm 3,

$$z_0 = \frac{0.2}{0.28461} \approx 0.7026$$

对于Arm 4,

$$z_0 = \frac{0.02}{0.07071} \approx 0.2828$$

则

$$KG(1) = 0.0023, KG(2) = 0.0490, KG(3) = 0.0401, KG(4) = 0.0193$$

(c)

最大的为 $KG(2)$ ，故选择arm 2。

(d)

如果立即commit，会选择当前均值最大的arm 1，即

$$\max_a \hat{\mu}_a = 0.70$$

实验的 $KG=0.0490$ ，这是再做一次实验可能带来的信息价值（期望改进量，注意不是概率）。

(e)

arm a	$\hat{\mu}$	σ_a	KG	$\tilde{\sigma}_a$	$z_0^{(a)}$
1	0.70	0.05	0.0023	0.0224	0.8944
2	0.65	0.20	0.0490	0.1789	0.2795
3	0.50	0.30	0.0401	0.2846	0.7026
4	0.68	0.10	0.0193	0.0707	0.2828

对比Arm 1和Arm 2，发现Arm 2的 $\hat{\mu}$ 更低，但是 KG 反而更大。

因为Arm 2的有效后验更新标准差 $\tilde{\sigma}_a$ 明显更大，且 $z_0^{(a)}$ 更小、使得 $f(z_0)$ 更大， KG 是这两项的乘积，所以Arm 2的 KG 明显比Arm 1大。

(f)

$$\tilde{\sigma}_3 = \frac{0.09}{\sqrt{0.09 + 0.25}} \approx 0.1543$$

$$\nu_{-3} = 0.70$$

$$z_0 \approx 1.296$$

$$f(z_0) \approx 0.046$$

$$KG(3) \approx 0.0071$$

比原来的 0.0401 显著下降。这是因为单次实验的有效后验更新标准差 $\tilde{\sigma}_a$ 显著变小（受限于噪声标准差 σ_ϵ ），即使 z_0 可能变大，但是 KG 整体下降，使得信息价值变小。