

edit time: 2026-06-08 00:22:44 PPO, RLHF的PPO, DPO

edit time: 2026-06-08 12:20:33 IPO, KTO, GRPO, 收敛性分析

本周一直在说的“目标”就是“损失函数”。

所有主流PO方法都是在优化KL正则化的目标，只是 Quality 的定义不同：

$$\max_{\pi} \mathbb{E}[\text{Quality}(\pi)] - \beta D_{KL}(\pi \| \pi_{\text{ref}})$$

所有 KL 正则化目标的最优策略都有形式：

$$\pi^*(y|x) \propto \pi_{\text{ref}}(y|x) \cdot f(y, x)$$

即所有PO方法都是在对同一个先验 π_{ref} 做指数倾斜 $\pi^* \propto \pi_{\text{ref}} e^{g/\beta}$ ，区别仅仅在于用什么能量/质量信号 $g(y)$ 。

PPO-Penalty和PPO-Clip

PPO-Penalty目标

$$L^{KL\text{PEN}}(\theta) = \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} A^{\pi_{\theta_{\text{old}}}} - \beta \cdot D_{KL}(\pi_{\theta_{\text{old}}}(\cdot|s) \| \pi_{\theta}(\cdot|s)) \right]$$

KL PEN大概是KL Penalty的意思罢（无慈悲

设TRPO的KL约束为 δ ，则最优 β^* 满足

$$\beta^* = \frac{1}{\alpha} = \sqrt{\frac{\nabla_{\theta} L^{CPI}(\theta^*)^T F^{-1} \nabla_{\theta} L^{CPI}(\theta^*)}{2\delta}}$$

其中 F 是Fisher矩阵， α 是TRPO的最优步长。

PPO-Clip目标

$$L^{CLIP}(\theta) = \mathbb{E}[\min(r(\theta)A, \text{clip}(r(\theta), 1 - \epsilon, 1 + \epsilon)A)]$$

其中 $r(\theta) = \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}$ 是重要性比率， ϵ 通常取0.1或0.2。

clipping与KL约束的关系：若 $r(\theta) \in [1 - \epsilon, 1 + \epsilon]$ 对所有 (s, a) 成立，则

$$D_{KL}(\pi_{old}||\pi_{\theta}) \leq \frac{\epsilon^2}{2(1-\epsilon)}$$

常用的 $\epsilon = 0.2$ 对应KL上界约为 0.025。

PPO-Clip的梯度：

$$\nabla_{\theta} L^{CLIP} = \mathbb{E}[r(\theta) A \cdot \nabla_{\theta} \log \pi_{\theta}(a|s) \cdot \mathbf{1}[r \in \text{activerregion}]]$$

在 $\theta = \theta_{old}$ 时退化为 $A \nabla_{\theta} \log \pi_{\theta}$ 。

其中，activerregion 是clip不起作用的区域，即 $r(\theta) \in (-\infty, 1 - \epsilon) \cup (1 + \epsilon, \infty)$ 。

直觉上，在clip范围之外的那些比例，对梯度影响为0。

RLHF中的PPO

RLHF目标为

$$\max_{\theta} \mathbb{E}_{x \sim y \sim \pi_{\theta}(\cdot|x)} [R(x, y)] - \beta D_{KL}(\pi_{\theta} || \pi_{ref})$$

其中 π_{ref} 是预训练模型。KL惩罚保持模型不偏离预训练太远，降低Reward Hacking问题。

KL正则化RLHF目标的最优策略 π^* 闭式解为：

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{ref}(y|x) \exp(\frac{R(x, y)}{\beta})$$

即最优策略等于：参考模型乘以奖励的指数加权，再归一化。“ **π 乘e的R比 β** ”

模型不是一味追高奖励，而是“在参考模型附近”移动——奖励高的回答概率上升、低的下降，KL惩罚拦着它别偏离原模型太远（ β 越大越保守）。

碎碎念：

这个形式看起来像是将 π_{ref} 对 R 进行了一个Softmax加权，所以 β 起到一个温度的作用。

- 温度趋于 0 时，KL弱约束， π^* 退化为只做reward最高的回答（贪婪策略）；
- 温度趋于 ∞ 时，KL强约束， π^* 退化到先验预训练模型策略 π_{ref} 。

其中分母这个归一化因子称为配分函数

$$Z(x) = \sum_y \pi_{ref}(y|x) \exp(\frac{R(x, y)}{\beta})$$

它需要对所有的可能回答 y 求和，但语言模型的回答空间过大、无法枚举。所以不考虑直接对闭式解的计算，而是以闭式解为指导，延伸出：

- 传统RLHF（先学奖励，再用PPO近似优化该目标）

- DPO/IPO/KTO/ORPO（利用闭式解把奖励消掉，直接从偏好数据训练策略）这两大流派。

RLHF闭式解通过固定 x ，优化RLHF目标（设 $\sum_y \pi(y) = 1$ ）即Lagrangian得到：

$$\mathcal{L} = \sum_y \pi(y) R(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{ref}(y)} + \lambda(1 - \sum_y \pi(y))$$

解法为对 $\pi(y)$ 求导。

当然也可以从 π^* 反解出奖励：

$$R(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

这个式子说，拿到对齐后的 π^* 就能读出奖励， $\log \frac{\pi^*}{\pi_{ref}}$ 正是对齐把回答 y 相对预训练先验抬高/降低了多少，而不必单独训练Reward Model，对应DPO。

与此同时， $\beta \log Z(x)$ 只依赖 x 而不依赖 y ，这意味着奖励的绝对值没有意义，只有同一prompt内的奖励差有意义，这也对应着 $\log Z$ 在DPO中必然抵消。

eg1. 验证一下温度 β 对RLHF最优解的奖励和先验模型的权衡，以及抬高/降低作用。

温度趋于0时，“温度太低，不鼓励创新和活泼”，模型趋于贪婪；

温度趋于无穷时，“温度太高，模型回归原始野性”(bushi。

假设prompt x = "Explain quantum physics"，三个候选回答及其奖励为：

回答	$R(x, y)$	$\pi_{ref}(y x)$
y_1 : "It's complicated."	0.2	0.5
y_2 : "Quantum physics studies..." (中等长度)	0.8	0.3
y_3 : "Quantum physics is..." (详细解释)	1.0	0.2

计算例如 $\beta = 1$ 时，

$$\pi^*(y_1) \propto 0.5 \times e^{0.2/1} \approx 0.611$$

$$\pi^*(y_2) \propto 0.3 \times e^{0.8/1} \approx 0.668$$

$$\pi^*(y_3) \propto 0.2 \times e^{1.0/1} \approx 0.544$$

归一化因子 $Z = 0.611 + 0.668 + 0.544 = 1.823$ ，之后归一化处理后得到

$$\pi^*(y_1) = 0.335, \pi^*(y_2) = 0.366, \pi^*(y_3) = 0.298$$

对这个 $\beta = 1$ 的例子，顺手从最优策略 π^* 反推一下奖励 R 可以得到：

$$R(y_1) = 1 \times \log \frac{0.335}{0.5} + \log 1.823 = 0.200$$

相同流程有 $R(y_2) \approx 0.800, R(y_3) \approx 1.000$ 。

这也符合DPO能工作的原因：从 π^*/π_{ref} 可以恢复奖励 R 。

同理对于五组 β (0, 0.5, 1.0, 2.0, ∞)，可以解得以下的总结表：

β	$\pi^*(y_1)$	$\pi^*(y_2)$	$\pi^*(y_3)$	$D_{KL}(\pi^* \pi_{ref})$
π_{ref}	0.500	0.300	0.200	0
2.0	0.415	0.337	0.248	0.016
1.0	0.335	0.366	0.298	0.057
0.5	0.201	0.401	0.398	0.201
$\rightarrow 0$	0	0	1	∞

可以由总结表看到，

β 足够大时，KL约束足够小，最优解分布完全与预训练分布 π_{ref} 相同；

β 较小时，最优解分布更倾向于刷高奖励，甚至于贪婪地只取最高奖励回答。

DPO

Bradley-Terry偏好模型 给定两个回答 y_w (winning) 和 y_l (losing)，偏好概率为

$$P(y_w \succ y_l | x) = \sigma(R(x, y_w) - R(x, y_l))$$

其中 $\sigma() = \frac{1}{1+e^{-}}$ 是sigmoid函数。

"偏好概率是奖励差取sigmoid"，这只是“奖励差越大，偏好越确定”的一个建模方式。

DPO目标的推导：

将RLHF最优策略的奖励表示 R 代入Bradley-Terry模型，得到DPO目标。具体而言，

$$R(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

代入Bradley-Terry模型得

$$P(y_w \succ y_l) = \sigma(R(y_w) - R(y_l))$$

$$= \sigma \left(\beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)} \right)$$

“beta乘log pi比pi 的差值再取sigmoid”

关键观察：RLHF最优策略中仍然存在的 $\log Z$ 抵消了，也就是说这个概率只通过奖励的“相对值”而不是绝对值建模。谁奖励相对更高，相应地偏好概率也更高。这让DPO可以直接优化。

接下来我们用 π_θ 代替 π^* 得到概率 $P_\theta(y_w, y_l)$ 。

当我们固定单个偏好对数据 (x, y_w, y_l) 时，可以把概率式子看作关于 θ 的似然函数：

$$L(\theta) = P_\theta(y_w, y_l)$$

（设随机变量 x 有概率密度函数 $f(x; \theta)$ ，

概率是 $P(x|\theta) = f(x; \theta)$ ，是关于 x 的函数、 θ 已知；

似然是 $L(\theta|x) = f(x; \theta)$ ，看作关于 θ 的函数、 x 已知。

似然：已知数据，反过来评价哪个参数更可能产生这个数据”）

从而我们想最大化所有偏好对的对数似然：

$$\max_{\theta} \sum_{(x, y_w, y_l)} \log P_\theta(y_w, y_l)$$

这也等价于最小化负对数似然。

当然，求和和期望是等价的（mini-batch近似期望），所以我们得到下述**DPO目标**

$$\mathcal{L}_{DPO}(\theta) = -\mathbb{E}_{(x, y_w, y_l) \sim} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{ref}(y_l|x)} \right) \right]$$

接下来推导一下单个偏好对的DPO梯度（整个数据集的DPO梯度是再取一个mini-batch）。

设

$$u = \beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)}$$

$$\mathcal{L} = -\log \sigma(u)$$

考虑到 σ 的导数

$$\sigma'(u) = \sigma(u)(1 - \sigma(u))$$

（顺便说一下，有恒等式： $\sigma(-u) = 1 - \sigma(u)$ ，即sigmoid函数关于 $(0, 0.5)$ 中心对称）

则有 $-\log \sigma$ 的导数

$$\frac{d}{du}(-\log \sigma(u)) = -\frac{\sigma'(u)}{\sigma(u)} = -(1 - \sigma(u))$$

考虑到 u 对 θ 的梯度

$$\nabla_{\theta} u = \beta \nabla_{\theta} \log \pi_{\theta}(y_w) - \beta \nabla_{\theta} \log \pi_{\theta}(y_l)$$

故有单个偏好对的损失 $\mathcal{L}$ 对 θ 的梯度

$$\nabla_{\theta} \mathcal{L} = -\beta(1 - \sigma(u))(\nabla_{\theta} \log \pi_{\theta}(y_w) - \nabla_{\theta} \log \pi_{\theta}(y_l))$$

我们发现“梯度系数 $\beta(1 - \sigma(u))$ ”有：

单个偏好对的损失取值 $1 - \sigma(u)$ ，正是当前模型预测错误的概率。

预测越错（正确的减去错误的得到的 u 越小），梯度越大。

梯度方向倾向于增加 y_w 的概率、减小 y_l 的概率。

可以证明，DPO的全局最优等于RLHF的最优：

若偏好数据由真实奖励 R^* 和Bradley-Terry模型生成，且 π_{θ} 有足够表达能力，则DPO的全局最优 π_{θ}^* 等于RLHF 的最优策略。证明如下：

在期望意义下（对所有偏好对），最优条件是

$$\sigma(u_{\theta}) = P^*(y_w, y_l), \text{ 对所有 } (y_w, y_l)$$

把Bradley-Terry模型： $P^* = \sigma(R^*(y_w) - R^*(y_l))$ 以及 u_{θ} 的定义代入上式，则有

$$\sigma\left(\beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)}\right) = \sigma(R^*(y_w) - R^*(y_l))$$

由于 σ 严格单调，去掉 σ 得

$$\beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)} = R^*(y_w) - R^*(y_l)$$

这是一个经典的可加性条件，它意味着存在某个常数 c ，使得

$$\beta \log \frac{\pi_{\theta}(y)}{\pi_{ref}(y)} = R^*(y) + c, y$$

这是因为：记 $f(y) = \beta \log \frac{\pi_{\theta}(y)}{\pi_{ref}(y)}$ ，则条件变形即 $f(y_w) - R^*(y_w) = f(y_l) - R^*(y_l)$ 。这个式子对任意的 y_w 和 y_l 都成立，所以这个差值是一个常数 c （比如固定 y_l 、则对任意 y_w 都有左边等于右边固定的常数，所以左边应该是一个不依赖于 y_w 的常数，与 y_w 无关；同理有右边与 y_l 无关，所以是常数 c ），从而有 $f(y) = R^*(y) + c$ 即上式。

从该式容易推得

$$\pi_{\theta}(y) \propto \pi_{ref}(y) e^{R^*(y)/\beta}$$

这正是RLHF的最优策略形式。

顺便补充一个用于eg2数值计算分析的小的二级结论。对于这里的 $\nabla_{\theta} \log \pi_{\theta}(y_w)$ 和 $\nabla_{\theta} \log \pi_{\theta}(y_l)$ （像上一节的策略梯度），有简单计算方法：假设

$$\pi_{\theta}(y|x) = \text{softmax}(h_{\theta}(x))_y = \frac{\exp(\theta(x, y))}{\sum_{y'} \exp(\theta(x, y'))}$$

对于单个样本 y ，固定 x ，有

$$\log \pi_{\theta}(y) = \theta(y) - \log \sum_{y'} \exp(\theta(y'))$$

对 θ 求梯度，有

$$\nabla_{\theta} \log \pi_{\theta}(y) = \nabla_{\theta} \theta(y) - \frac{\sum_{y'} \exp(\theta(y')) \nabla_{\theta} \theta(y')}{\sum_{y'} \exp(\theta(y'))}$$

注意到 $\pi_{\theta}(y') = \text{softmax}(h_{\theta}(y'))$ （分母求和用的是 y 没关系），则有梯度应为

$$\nabla_{\theta} \log \pi_{\theta}(y) = \nabla_{\theta} \theta(y) - \sum_{y'} \pi_{\theta}(y') \nabla_{\theta} \theta(y')$$

这正是期望形式

$$\nabla_{\theta} \log \pi_{\theta}(y) = \nabla_{\theta} \theta(y) - \mathbb{E}_{y' \sim \pi_{\theta}}[\nabla_{\theta} \theta(y')]$$

对于线性参数化的特例，有 $\theta(y) = \theta^T \psi(y)$ ，此时有 $\nabla_{\theta} \theta(y) = \psi(y)$ 。

假设 $\psi(y_w)$ 记作 e_w （代表“赢家特征”）， $\mathbb{E}_{y' \sim \pi_{\theta}}[\nabla_{\theta} \theta(y')]$ 记作 π （代表“平均特征”），则有

$$\nabla_{\theta} \log \pi_{\theta}(y_w) = e_w - \pi$$

同理有 $\nabla_{\theta} \log \pi_{\theta}(y_l) = e_l - \pi$ 。

这个小结论就像是在说， $\log \pi$ 的梯度值，是赢家那一项为1，减去平均策略。

eg2. 假设有Softmax策略，3个token: y_w, y_l, y_{other} ， $\pi_{\theta}(y) = \frac{e^{\theta_y}}{\sum e^{\theta}}$ ，参数 $\theta = (\theta_w, \theta_l, \theta_o)$ ，初始 $\theta^{(0)} = (0, 0, 0)$ ， $\pi_{\theta}^{(0)} = (1/3, 1/3, 1/3)$ ， $\pi_{ref} = (1/3, 1/3, 1/3)$ ， $\beta = 1$ ，学习率 $\alpha = 0.5$ ，尝试对单个偏好对执行完整的DPO训练过程。

解：直觉上， h_w 就是 y_w 的 $\log \frac{\pi}{\pi}$ ， u 是 $\beta(h_w - h_l)$ ， $\mathcal{L}$ 是 $-\log \sigma(u)$ 。
初始loss：

$$h_w = \log \frac{\pi_{\theta}(y_w)}{\pi_{ref}(y_w)} = \log \frac{1/3}{1/3} = 0$$

同理有 $h_l = 0$ 。则有 $u = \beta(h_w - h_l) = 0, \mathcal{L} = -\log \sigma(0) = 0.693$ 。
梯度：（我们上述的二级小结论）

$$\begin{aligned}\nabla_{\theta} \log \pi_{\theta}(y_w) &= e_w - \pi_{\theta}^{(0)} = (1, 0, 0) - (1/3, 1/3, 1/3) = (2/3, -1/3, -1/3) \\ \nabla_{\theta} \log \pi_{\theta}(y_l) &= e_l - \pi_{\theta}^{(0)} = (0, 1, 0) - (1/3, 1/3, 1/3) = (-1/3, 2/3, -1/3) \\ \nabla_{\theta} u &= \beta(\nabla_{\theta} \log \pi_{\theta}(y_w) - \nabla_{\theta} \log \pi_{\theta}(y_l)) = (1, -1, 0) \\ \nabla_{\theta} \mathcal{L} &= -(1 - \sigma(0)) \cdot (1, -1, 0) = (-0.5, 0.5, 0)\end{aligned}$$

更新参数：

$$\theta^{(1)} = \theta^{(0)} - \alpha \nabla_{\theta} \mathcal{L} = (0, 0, 0) - 0.5 \times (-0.5, 0.5, 0) = (0.25, -0.25, 0)$$

新策略：

$$\begin{aligned}Z &= e^{0.25} + e^{-0.25} + e^0 = 3.063 \\ \pi^{(1)} &= (1.284, 0.779, 1)/3.063 = (0.419, 0.254, 0.327)\end{aligned}$$

新loss：

$$\begin{aligned}h_w &= \log \frac{0.419}{1/3} = 0.229, \quad h_l = \log \frac{0.254}{1/3} = -0.272, \quad u = 1 \times (0.229 - (-0.272)) = 0.501, \\ \mathcal{L}^{(1)} &= -\log \sigma(0.501) = 0.474\end{aligned}$$

把上述数值整理为表格：

迭代	$\pi(y_w)$	$\pi(y_l)$	$\pi(y_o)$	u	Loss
0	0.333	0.333	0.333	0	0.693
1	0.419	0.254	0.327	0.501	0.474

继续迭代到收敛，会发现 θ_w 慢慢增大、 θ_l 慢慢减小，以相反方向增长，而与偏好无关的 θ_o 保持为0。极限情况下 $\pi(y_w) \rightarrow 1$ ， $\pi(y_l) \rightarrow 0$ ，但收敛变慢（梯度趋于0）。

IPO和KTO

IPO只是一个DPO的补丁，效果也未必比DPO更好，简单介绍一下。
DPO 假设Bradley-Terry 模型完美成立。但实际中：

- 人类偏好有噪声
- 偏好可能不传递 ($A \succ B$ 且 $B \succ C$ 但 $A \not\succ C$)
- 极端奖励差会导致数值问题

IPO 的想法：用更鲁棒的损失函数。

IPO的目标是：

$$\mathcal{L}_P(\theta) = \mathbb{E} \left[\left(\log \frac{\pi_\theta(y_w)}{\pi_{\text{ref}}(y_w)} - \log \frac{\pi_\theta(y_l)}{\pi_{\text{ref}}(y_l)} - \frac{1}{2\beta} \right)^2 \right]$$


KTO将DPO/IPO的偏好“对”，放松到只需要单独标注的数据（pointwise）。从而可以只有点赞或点踩的数据。

KTO基于前景理论中的“损失厌恶”思想。

KTO的目标是：

$$\mathcal{L}_K(\theta) = \mathbb{E}_{x,y} \left[w(y) \cdot \left(1 - v \left(\beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)} - \text{ref} \right) \right) \right]$$

GRPO



Extended Data Fig. 2 | Illustration of the proposed GRPO for RL-based training. In the proposed framework, a LLM is used as a policy model to generate responses $\{o_1, o_2, \dots, o_G\}$ conditioned on a given query q . Each response within the group is evaluated by a reward model—either learned (model-based) or manually specified (rule-based)—to assign a scalar reward signal. Subsequently, GRPO computes the relative advantages of each group member based on their assigned rewards. Rather than relying on an explicit value function, as in PPO,

GRPO directly estimates advantages from the intra-group reward distribution. The policy parameters are then updated to maximize the expected reward while simultaneously minimizing divergence from a reference policy, typically quantified through the KL divergence. By eliminating the need for a separate value network, GRPO offers a simplified yet effective alternative to traditional actor-critic methods such as PPO.

这个要重点一些。

就像DPO一样，我们希望干掉critic模型 $V(s)$ ，这样大模型能用少得多的成本进行训练。于是，GRPO用组内相对奖励代替critic。

对每个prompt x ，采样 G 个回答 $\{y_1, \dots, y_G\}$ ，计算**标准化优势估计**：

$$\hat{A}_i = \frac{R(x, y_i) - \bar{R}}{\sigma_R}$$

其中奖励平均 $\bar{R} = \frac{1}{G} \sum_j R(x, y_j)$ ，标准差 $\sigma_R = \sqrt{\frac{1}{G} \sum_j (R(x, y_j) - \bar{R})^2}$ 。

则GRPO的目标为：

$$\mathcal{L}_{GRPO}(\theta) = -\mathbb{E}_{x, \{y_i\}} \left[\frac{1}{G} \sum_{i=1}^G \min \left(r_i \hat{A}_i, \text{clip}(r_i, 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) \right]$$

为什么可以用这里的奖励平均 $\bar{R}$ ？

因为每个 R_i 独立同分布从 $\pi(\cdot|x)$ 采样得到，是 $V(x)$ 的无偏估计，所以它们的样本均值 $\bar{R}$ 同样也是 $V(x)$ 的蒙特卡洛无偏估计。

可以证明，**GRPO的优势估计是无偏的**：设 $R(x, y)$ 的期望为 μ ，可以证明 $\mathbb{E}[\hat{A}_i] = 0$ ，即标准化后的相对优势期望为零，像真正的优势函数一样。证明如下：

$$\mathbb{E}[\hat{A}_i] = \mathbb{E} \left[\frac{R_i - \bar{R}}{\sigma_R} \right] = \mathbb{E} \left[\frac{R_i - \frac{1}{G} \sum_j R_j}{\sigma_R} \right] = \mathbb{E} \left[\frac{R_i}{\sigma_R} \right] - \frac{1}{G} \sum_j \mathbb{E} \left[\frac{R_j}{\sigma_R} \right]$$

由于 R_i 和 R_j 同分布， $\mathbb{E} \left[\frac{R_i}{\sigma_R} \right] = \mathbb{E} \left[\frac{R_j}{\sigma_R} \right]$ 。故有 $\mathbb{E}[\hat{A}_i] = 0$ 得证。

eg3. 一个简单的数值例子

Prompt x: "Write a poem about AI"，采样 $G = 4$ 个回答，奖励： $R = [0.8, 0.6, 0.9, 0.5]$ ，尝试计算一下GRPO的优势估计。

$$\bar{R} = (0.8 + 0.6 + 0.9 + 0.5)/4 = 0.7$$

$$\sigma_R = \sqrt{\frac{1}{4} ((0.8 - 0.7)^2 + (0.6 - 0.7)^2 + (0.9 - 0.7)^2 + (0.5 - 0.7)^2)} = \sqrt{0.025} = 0.158$$

标准化优势应为：

$$\hat{A} = (0.8 - 0.7, 0.6 - 0.7, 0.9 - 0.7, 0.5 - 0.7)/0.158 = (0.63, -0.63, 1.26, -1.26)$$

优势估计无偏可以通过把各项加到一起验证： $\sum_i \hat{A}_i = 0$ 。

对于上述的标准化优势，我们可以看到 y_3 最好、 y_4 最差，这和原始奖励的趋势是一致的。GRPO会增加 y_3 的概率，减小 y_4 的概率。

所以GRPO压根就是直接使用了原始奖励 R ，只是标准化了一下。

对GRPO的局限性的讨论和改进尝试可以看DAPO和GSPO。

顺便补充一些Deepseek V4论文中的讨论。

根据论文第5.1节说明：

"Following pre-training, we conducted a post-training phase to yield the final models of DeepSeek-V4 series. Although the training pipeline largely mirrored that of DeepSeek-V3.2, **a critical methodological substitution was made: the mixed Reinforcement Learning (RL) stage was entirely replaced by On-Policy Distillation (OPD**; Gu et al., 2024; Lu and Lab, 2025)."

既然纯粹的RL pipeline被替换成了对多个领域首先各自GRPO训练专家模型、然后再把它们OPD蒸馏到一起，看来是后者能够有更高的提升了。

1. 单专家训练用GRPO（说明它够用）
2. 多专家融合改用OPD（说明GRPO不适合这个场景）
3. 难验证任务用GRM（说明GRPO依赖的组内比较在难验证任务上可能不够）

收敛性分析

定理 13.1 (PPO 的近似单调改进). 设 ϵ 是 clip 参数, $\delta = \frac{\epsilon}{1-\epsilon}$. 若每次更新满足 $D_{KL}(\pi_{old} \parallel \pi_{new}) \leq c\delta^2$ (某常数 c), 则:

$$J(\pi_{new}) \geq J(\pi_{old}) - O(\delta^2)$$

即策略改进是近似单调的。

证明思路. Step 1: 回顾 Kakade-Langford 界

$$J(\pi') \geq L_{\pi}(\pi') - C \cdot D_{KL}^{\max}(\pi \parallel \pi')$$

Step 2: Clip 限制了 KL

由 Clip 机制, $r = \pi' / \pi \in [1 - \epsilon, 1 + \epsilon]$.

单样本 KL: $KL(\pi \parallel \pi') = -\log r \leq \epsilon$ (当 r 接近边界时)

Step 3: 代入得到界

$$J(\pi') \geq L_{\pi}(\pi') - O(\epsilon)$$

由于 $L_{\pi}(\pi') \geq L_{\pi}(\pi) = J(\pi)$ (clip 后的代理目标仍然非负改进), 我们有近似单调性。□

定理 13.2 (DPO 的收敛性——凸优化视角). DPO 损失函数是 θ 的非凸函数, 但在 log-linear 策略参数化下, 有局部收敛保证。

证明思路. Step 1: DPO 损失的 Hessian

$$\mathcal{L} = -\log \sigma(u), \quad \text{其中 } u = \beta(h_w - h_t), \quad h = \log \frac{\pi_\theta}{\pi_{\text{ref}}}$$

$$\nabla_\theta^2 \mathcal{L} = \beta^2 \sigma(u)(1 - \sigma(u))(\nabla_\theta h_w - \nabla_\theta h_t)(\nabla_\theta h_w - \nabla_\theta h_t)^T + \dots$$

Step 2: 局部凸性条件

当 $|u|$ 不太大时 ($\sigma(u)(1 - \sigma(u))$ 远离 0), Hessian 的主项是半正定的。

Step 3: 收敛速率

在局部凸区域, 梯度下降以 $O(1/t)$ 速率收敛。

在非凸区域, 可能收敛到局部最优或鞍点。□

10 RLHF的最优策略闭式解

从优化的视角推导一下KL正则化RL的闭式解, 即RLHF最优策略。

考虑以下目标:

$$\max_{\pi(\cdot|x)} \mathbb{E}_{y \sim \pi(\cdot|x)} [R(y|x)] - \beta D_{KL}(\pi(\cdot|x) || \pi_{\text{ref}}(\cdot|x)), \quad s.t. \quad \sum_y \pi(y|x) = 1$$

解题备注:

- 目标里面每一处参数都强调了“给定 x ”, 这是有**依赖关系**的。
- 另外 $\pi(\cdot|x)$ 这个写法是强调“**概率分布**”这个整体, 而 $R(y|x)$ 则强调输出恰好为**特定值** y 。

下述用Lagrange乘子法求闭式解。

(a) 我们前述目标定义中说明了每一处参数都需要强调“给定 x ”。但在下述推导中, 为了书写方便起见, 我们在中间过程中暂时省略“ $|x$ ”, 而只写“输出为特定值 y ”。则

$$D_{KL} = \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)}$$

则目标应为

$$\max_{\pi} \sum_y \pi(y) R(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)}$$

(b) 对于上述优化目标和约束, 对应的Lagrangian应为

$$\mathcal{L}(\pi, \lambda) = \sum_y \pi(y) R(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)} + \lambda(1 - \sum_y \pi(y))$$

(c) $\mathcal{L}$ 对某个特定的 y 求偏导 (顺便注意 $\frac{\partial(\pi(y) \log \pi(y))}{\partial \pi(y)} = \log \pi(y) + 1$), 则求和式 $\sum_y$ 中其余项求导都为0, 只有包含这个特定的 y 的项对求导有影响。令求偏导的结果等于0则有

$$R(y) - \beta \log \pi(y) - \beta + \beta \log \pi_{ref}(y) - \lambda = 0$$

(d) 由上式解出 $\pi(y)$ 得

$$\pi(y) = \pi_{ref}(y) \exp\left(\frac{R(y) - \beta - \lambda}{\beta}\right) = \pi_{ref}(y) \cdot e^{-1-\lambda/\beta} \cdot e^{R(y)/\beta}$$

记与 y 无关的部分 $e^{-1-\lambda/\beta} = 1/Z(x)$ ，则推得闭式解

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{ref}(y|x) \exp(R(y|x)/\beta)$$

“ π 乘 e 的 R 比 β ”

(e) 由归一化条件 $\sum_y \pi^*(y|x) = 1$ ，闭式解两侧对 y 求和解得

$$Z(x) = \sum_y \pi_{ref}(y|x) \exp(R(y|x)/\beta)$$

(f) 反解Reward。对(d)求得的闭式解两边取 $\log$ ，整理得到

$$R(y|x) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

该式子用于DPO，代入BT模型的奖励差以消去 $Z(x)$ 。

(g) 手算 π^* 的物理意义。

考虑到 $\pi^* \propto \pi_{ref}(y) e^{R(y)/\beta}$ ，正比系数为 $1/Z(x)$ ，则计算 π^* 时应该首先求得两个未归一化的 $\pi_{ref}(y_i) e^{R(y_i)/\beta}$ ，然后再归一化得到最优策略。

当 $\beta = 0.1$ 时，派乘 e 的 R 比 β 值为 $(0.5 \cdot e^{1/0.1}, 0.5 \cdot e^{0/0.1}) = (0.5e^{10}, 0.5)$ ，归一化得到 $(1, 0)$ 。

当 $\beta = 1$ 时，值为 $(0.5e^1, 0.5e^0) = (1.359, 0.5)$ ，归一化得到 $(0.731, 0.269)$ 。

当 $\beta = 10$ 时，值为 $(0.5e^{0.1}, 0.5e^0)$ ，归一化得到 $(0.525, 0.475)$ 。

(h) β 小的时候结果偏向奖励更高的， β 大的时候结果与参考策略更相近。 β 控制奖励与KL散度约束（分布变化）的权衡。

9 GRPO的相对优势与零均值性

(a) $G = 4, R = 0.8, 0.6, 0.9, 0.5$ ，则

$$\bar{R} = 0.7$$

$$\sigma_R = \sqrt{0.025} \approx 0.158$$

$$\hat{A}_i = (R_i - \bar{R})/\sigma_R$$

则有

$$\hat{A} = (0.632, -0.632, 1.265, -1.265)$$

(b) 从数值上有 $\sum_i \hat{A}_i = 0$ 。而证明中有

$$\sum_i (R_i - \bar{R}) = \sum_i R_i - G\bar{R} = G\bar{R} - G\bar{R} = 0$$

(c) 因为 R_i 是从 $y \sim \pi(\cdot|x)$ 分布独立采样得到的奖励，且

$$\mathbb{E}[\bar{R}] = \frac{1}{G} \sum_{i=1}^G \mathbb{E}[R_i] = V(x)$$

故 $\bar{R}$ 为 $V(x) = \mathbb{E}_{y \sim \pi}[R(x, y)]$ 的无偏Monte Carlo估计。

(d)

维度	PPO（用 critic $V\phi(s)$ ）	GRPO（用群体均值 $\bar{R}$ ）
训练成本	需额外训练一个 critic 网络，增加计算和内存	无需 critic，节省训练开销
样本效率	单 prompt 采 1 个 y 即可（借助 critic 估计 baseline）	每个 prompt 需采 $G \geq 2$ 个 y 才能获得有意义的 baseline
适用任务	适合小模型、单次采样快，critic 容易训练	适合 LLM 生成（一次生成 G 个回答并行），避免 critic 偏差

8 PPO-Clip

设 $\epsilon = 0.2$ ，则clip区间为 $[0.8, 1.2]$ ，设 $L^{CLIP} = \min(rA, \text{clip}(r, 0.8, 1.2) \cdot A)$ 。

(a)(b) 填表。

样本	r	A	rA	$\text{clip}(r) \cdot A$	L^{CLIP}	激活/未激活
1	1.5	+2	3	2.4	2.4	激活
2	0.6	+1	0.6	0.8	0.6	未激活
3	1.5	-1	-1.5	-1.2	-1.5	未激活
4	0.5	-2	-1	-1.6	-1.6	激活
5	1.0	+1	1	1	1	未激活

(c)

当 $A > 0$ 时， $r > 1 + \epsilon = 1.2$ 时clip才激活。如样本1激活，而样本2和5都未激活。

当 $A < 0$ 时， $r < 1 - \epsilon = 0.8$ 时clip才激活。如样本4激活，而样本3未激活。

(d)

目标 L^{CLIP} 不发生变化。

在 $r > 1 + \epsilon$ 区域，梯度为0。

7 GAE的几何级数化简

回忆TD误差形式为 $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ ，把若干个 δ 累加，就得到 n 步优势估计 $\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}$ 。GAE把所有 n 步估计做加权平均，权重按 λ 几何衰减。 $(1 - \lambda)$ 是归一化常数)：

$$\hat{A}_t^{GAE(\lambda)} = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \hat{A}_t^{(n)}$$

求证上述GAE的定义式等价于

$$\hat{A}_t^{GAE(\lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

(a) 首先把 n 步优势估计的定义式代入GAE的定义式，有

$$\hat{A}_t^{GAE(\lambda)} = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}$$

(b) δ_{t+l} 在双重求和条件 $1 \leq n < +\infty, 0 \leq l \leq n - 1$ 中包含以下的项：

t
t t+1
t t+1 **t+2**
...
t t+1 **t+2** ... t+n-1
...

从上往下 n 的值递增，从左往右 l 的值递增。

对于每个固定的 l ， δ_{t+l} 出现在 $n - 1 \geq l$ 即 $n \geq l + 1$ 的项中。例如上述 $l = 2$ 这一列， δ_{t+2} 出现在 $n \geq 3$ 这些行中（除了前两行之外的行）。

故交换后的双重求和条件为 $0 \leq l < +\infty, l + 1 \leq n < +\infty$ 。交换求和顺序得

$$\hat{A}_t^{GAE(\lambda)} = (1 - \lambda) \sum_{l=0}^{\infty} \gamma^l \delta_{t+l} \sum_{n=l+1}^{\infty} \lambda^{n-1}$$

(c) 计算内层几何级数。

设 $m = n - 1$ ，则有

$$\sum_{m=l}^{\infty} \lambda^m = \lim_{x \rightarrow \infty} \frac{\lambda^l (1 - \lambda^x)}{1 - \lambda} = \frac{\lambda^l}{1 - \lambda} (0 < \lambda < 1)$$

(d) 接下来把内层几何级数代入，消去 $1 - \lambda$ ，即得到所求证的

$$\hat{A}_t^{GAE(\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$$

(e) 极限检查。把 $\lambda = 0$ 和 $\lambda = 1$ 分别代入简洁形式，发现：

$\lambda = 0$ 时， $\hat{A} = \delta_t$ 。（因为这一项的 $l = 0$ ， λ 没啥用了）

这正对应于单步TD，低方差高偏差。

$\lambda = 1$ 时， $\hat{A} = \sum_{l=0}^{\infty} \gamma^l \delta_{t+l}$ ，可以证明 $\hat{A} = G_t - V(s_t)$ 。

这正对应于MC偏差，高方差无偏差。

下证 $\hat{A} = G_t - V(s_t)$ 。首先代入 δ_{t+l} 的定义，有

$$\hat{A}_t = \sum_{l=0}^{\infty} \gamma^l (r_{t+l} + \gamma V(s_{t+l+1}) - V(s_{t+l}))$$

$$\hat{A}_t = \sum_{l=0}^{\infty} \gamma^l r_{t+l} + \sum_{l=0}^{\infty} \gamma^{l+1} V(s_{t+l+1}) - \sum_{l=0}^{\infty} \gamma^l V(s_{t+l})$$

设 $k = l + 1$ 代入第二个和式，并将第三个和式拆成第一项和剩余和式。

$$\hat{A}_t = \sum_{l=0}^{\infty} \gamma^l r_{t+l} + \sum_{k=1}^{\infty} \gamma^k V(s_{t+k}) - V(s_t) - \sum_{k=1}^{\infty} \gamma^k V(s_{t+k})$$

$$\hat{A}_t = \sum_{l=0}^{\infty} \gamma^l r_{t+l} - V(s_t)$$

故 $\hat{A}_t = G_t - V(s_t)$ 得证。

6 策略梯度定理的log-trick

参数化策略 $\pi_{\theta}(a|s)$ ，目标是最大化期望回报：

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right] = \mathbb{E}_{s_0} [V^{\pi_{\theta}}(s_0)]$$

策略梯度定理写作

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{s \sim d^{\pi}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$$

其中 $\nabla_{\theta} \log \pi$ 是log-trick的产物。

(a) 设 $f(\theta) > 0$ 是可微函数。证明 $\nabla_{\theta} \log f(\theta) = \nabla_{\theta} f(\theta) / f(\theta)$ 。

设 $u = f(\theta)$ ，则 $\nabla_{\theta} \log f(\theta) = \frac{d \log u}{du} \nabla_{\theta} u = \nabla_{\theta} f(\theta) / f(\theta)$ 。

(b) 代入 $f = \pi_{\theta}(a|s)$ ，则有

$$\nabla_{\theta} \pi_{\theta}(a|s) = \pi_{\theta}(a|s) \cdot \nabla_{\theta} \log \pi_{\theta}(a|s)$$

(c) 考虑期望

$$\mathbb{E}_{a \sim \pi_{\theta}}[h(a)] = \sum_a \pi_{\theta}(a|s) h(a)$$

对 θ 求导，则应该等于对每一项的求导再加起来，有

$$\nabla_{\theta} \mathbb{E}[h(a)] = \sum_a [\nabla_{\theta} \pi_{\theta}(a|s)] h(a)$$

(d) 把(b)代入(c)，即利用 $\nabla \log \pi$ 替换 $\nabla \pi / \pi$ ，这就是log-trick。得到

$$\nabla_{\theta} \mathbb{E}_{a \sim \pi_{\theta}}[h(a)] = \mathbb{E}_{a \sim \pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot h(a)]$$

观察这个式子，我们发现左边是一个抽样分布的期望求梯度（并不能采样估计），右边是一团东西的期望（可采样估计）。我们把不能采样估计的形式转化成了可采样估计的形式。

(e) 为什么不直接用 $\nabla \pi / \pi$ 而要用 $\nabla \log \pi$ ？

因为当 $\pi(a|s) \rightarrow 0$ 时，左边的 $\nabla \pi / \pi$ 的分母过小，必须除以这个小分母、容易溢出。而右边的 $\nabla \log \pi$ 则是有限值，可以通过先算 $\log \pi$ （有限、幅度适中的数）然后再自动微分得到。

(f) 考虑softmax策略 $\pi_{\theta}(a) = \frac{e^{\theta_a}}{\sum_b e^{\theta_b}}$ ，假设有3个动作。证明

$$\frac{\partial \log \pi_{\theta}(a)}{\partial \theta_c} = \mathbf{1}[a = c] - \pi_{\theta}(c)$$

即

$$\nabla_{\theta} \log \pi_{\theta}(a) = e_a - \pi$$

其中 e_a 是第 a 个标准基向量（即第 a 个元素为1、其余元素为0）， $\pi = (\pi_1, \pi_2, \pi_3)^T$ 。下证。

首先对softmax取 $\log$ ，得到

$$\log \pi_{\theta}(a) = \theta_a - \log \sum_b e^{\theta_b}$$

接下来关于 θ_c 求偏导，得到

$$\frac{\partial \log \pi_{\theta}(a)}{\partial \theta_c} = \mathbf{1}[a = c] - \frac{e^{\theta_c}}{\sum_b e^{\theta_b}} = \mathbf{1}[a = c] - \pi_{\theta}(c)$$

整理为梯度即为

$$\nabla_{\theta} \log \pi_{\theta}(a) = e_a - \pi$$

这个式子是softmax取log梯度所一定满足的性质，很常用。

(g) 假设 $\pi = (0.5, 0.3, 0.2)$ ，则这三个动作各自的score向量应该为：

$$e_1 - \pi = (1, 0, 0) - (0.5, 0.3, 0.2) = (0.5, -0.3, -0.2)$$

$$e_2 - \pi = (0, 1, 0) - (0.5, 0.3, 0.2) = (-0.5, 0.7, -0.2)$$

$$e_3 - \pi = (0, 0, 1) - (0.5, 0.3, 0.2) = (-0.5, -0.3, 0.8)$$

验证

$$\begin{aligned}\mathbb{E}_{a \sim \pi}[\nabla \log \pi] &= \sum_a \pi_a (e_a - \pi) \\ &= 0.5 \times (0.5, -0.3, -0.2) + 0.3 \times (-0.5, 0.7, -0.2) + 0.2 \times (-0.5, -0.3, 0.8) = (0, 0, 0)\end{aligned}$$

得证。

5 Q-learning和SARSA

(a) SARSA:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

初始时 $Q_{2 \times 2}$ 为全0。

考虑更新后的 $Q(s_1, a_1)$:

$$Q(s_1, a_1) \leftarrow 0 + 0.5 \times [1 + 0.9 \times 1 - 0] = 0.95$$

注意它用到的是 $Q(s_t, a_t)$ 和 $Q(s_{t+1}, a_{t+1})$ 两个表项。

(b) Q-learning:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)]$$

为了计算 $\max$ 需要比较 $Q(s_2, a_1)$ 和 $Q(s_2, a_2)$ 的大小，发现前者更大。故

$$Q(s_1, a_1) \leftarrow 0 + 0.5 \times [1 + 0.9 \times 2 - 0] = 1.4$$

(c) 相差 $1.4 - 0.95 = 0.45$ 。发现Q-learning给出更大的更新，因为它用的是 Q 值更大的表项。

(d)

SARSA是on-policy的，使用的是实际采样得到的下一个动作 a_{t+1} ，评估的是行为策略本身。

Q-learning是off-policy的，因为用了 $\max$ ，所以评估的是贪婪策略，而不是行为策略。

还可以看到，Q-learning的 $\max$ 会带来系统性过估计，总是高估 Q 。

4 baseline降低方差

考虑单状态，标量参数。

设 score $\psi = \nabla_{\theta} \log \pi_{\theta}(a|s)$,

回报为 G , 回报的期望和方差分别为 μ 和 σ^2 ,

策略梯度估计 $\hat{g} = \psi \cdot G$, 加baseline后 $\hat{g}_b = \psi \cdot (G - b)$,

假设score ψ 与回报 G 独立, score有 $\mathbb{E}[\psi] = 0$, $\mathbb{E}[\psi^2] = I$ 。

(a) 证明添加baseline有期望不变性。

$$\mathbb{E}[\hat{g}_b] = \mathbb{E}[\hat{g}] - \mathbb{E}[\psi \cdot b] = \mathbb{E}[\hat{g}] - b\mathbb{E}[\psi] = \mathbb{E}[\hat{g}]$$

(b) 推导无baseline的方差形式。

$$\text{Var}[\hat{g}] = \mathbb{E}[\psi^2 G^2] - (\mathbb{E}[\psi G])^2$$

考虑到 ψ 和 G 独立, 也有 ψ^2 与 G^2 独立。则有

$$\text{Var}[\hat{g}] = \mathbb{E}[\psi^2] \mathbb{E}[G^2] - (\mathbb{E}[\psi] \mathbb{E}[G])^2$$

其中 $\mathbb{E}[\psi] = 0$, $\mathbb{E}[\psi^2] = I$, $\mathbb{E}[G^2] = \text{Var}[G^2] + (\mathbb{E}[G])^2 = \sigma^2 + \mu^2$ 。则有

$$\text{Var}[\hat{g}] = I(\sigma^2 + \mu^2)$$

(c) 推导有baseline的方差形式。

加baseline后, $G - b$ 的期望为 $\mu - b$, 方差仍为 σ^2 。

则有

$$\text{Var}[\hat{g}_b] = I(\sigma^2 + (\mu - b)^2)$$

(d) 把(c)看作关于 b 的二次函数, 使得方差最小的 b^* 显然应有 $b^* = \mu$ 。

根据状态值函数的定义 (期望累积折扣回报), $V = \mathbb{E}[G_t] = \mu$ 。故有 $b^* = \mu = V$ 。

此时的最小方差应为 $\text{Var}[\hat{g}_{b^*}] = I\sigma^2$ 。

(e) 我们发现从(b)到(c), 期望有了二次程度的下降。

假设 $\mu = 100, \sigma = 10, I = 1$, 则加baseline前

$$\text{Var}[\hat{g}] = 1 \times (10^2 + 100^2) = 10100$$

加baseline后, 有 $b^* = \mu = 100$,

$$\text{Var}[\hat{g}_b] = 1 \times (100 + (10^2 - 100)^2) = 100$$

方差降低了 $10100/100 = 101$ 倍。

Critic 之所以学状态值函数 V , 就是因为 V 是最优baseline。

用 $A(s, a) = Q(s, a) - V(s)$ 替换 Q , 相当于把梯度信号零均值化——只保留”这个动作比平均好多少”, 丢掉与动作无关的公共项 V 。(e) 中”方差降101倍”就是这个零均值化的威力。为什么baseline 只能依赖状态 s 、不能依赖动作 a ? 因为否则(a) 中”期望不变” 会被破坏。

3 Monte Carlo评估

Monte Carlo是用累积折扣回报 G_t 来估计期望累积折扣回报（即状态-值函数） $V(s)$ 。
一条轨迹为：（ $\gamma = 0.5$ ）

$$s_1 \xrightarrow{r_1=1} s_2 \xrightarrow{r_2=2} s_3 \xrightarrow{r_3=0} s_1 \xrightarrow{r_4=3} \text{终止}.$$

其中状态 s_1 被访问了两次，分别在 $t = 1$ 和 $t = 4$ 。

(a) 根据累积折扣回报return的定义，计算

$$G_4 = 3$$

$$G_3 = 0 + 0.5 \times 3 = 1.5$$

$$G_2 = 2 + 0.5 \times 1.5 = 2.75$$

$$G_1 = 1 + 0.5 \times 2.75 = 2.375$$

(b) Every-visit MC：把每次访问 s 的 G_t 都拿来平均。

状态	访问发生在	$V(s)$ 的every-visit估计
s_1	$t = 1, 4$	$(2.375 + 3)/2 = 2.6875$
s_2	$t = 2$	2.75
s_3	$t = 3$	1.5

(c) First-visit MC：每条轨迹中只用首次访问的 G_t 来估计值函数 $V(s)$ 。

状态	访问发生在	$V(s)$ 的first-visit估计
s_1	$t = 1, 4$	2.375
s_2	$t = 2$	2.75
s_3	$t = 3$	1.5

其中状态 s_1 的估计与Every-visit不同。因为该状态被访问多次，**在单条轨迹内**，First-visit只使用第一次访问到的 G_t ，而Every-visit使用每次访问到的 G_t 的平均。

（注意，不同轨迹应该用增量平均公式更新）

(d) 假设第二条轨迹有 s_1 的return $G^{(2)} = 5$ 。则有

$$\begin{aligned} V_{new}(s_1) &= V_{old}(s_1) + \frac{1}{n}(G^{(2)} - V_{old}(s_1)) \\ &= 2.375 + \frac{1}{2} \times (5 - 2.375) = 3.6875 \end{aligned}$$

(e) 对比MC和TD。MC必须等到整个episode结束才能更新（因为整个episode结束才能知道所有的 G_t ），而 TD(0) 每步就能更新。

例如机器人在无边界的二维连续平面上执行任务，永不终止，这种情况MC不能用、而TD可以用。

2 值迭代

考虑2状态MDP $\{A, B\}$ ， $\gamma = 0.5$ ，单动作（即策略评估，策略固定，不需要考虑策略的改进。如果每个状态只有一个动作，那么策略自然固定。）

- 状态A：奖励2，确定转到B。
- 状态B：奖励0，确定转到A。

Bellman更新即：

$$V_{k+1}(A) = 2 + 0.5V_k(B)$$

$$V_{k+1}(B) = 0 + 0.5V_k(A)$$

(a) 取不动点，有联立方程。

$$V(A) = 2 + 0.5V(B), V(B) = 0.5V(A)$$

解得

$$V^*(A) = \frac{8}{3}, V^*(B) = \frac{4}{3}$$

(b) 从 $V_0 = (0, 0)$ 开始，逐步代入Bellman更新公式，有

k	$V_k(A)$	$V_k(B)$	误差 $\ V_k - V^*\ _\infty$
0	0	0	8/3
1	2	0	4/3
2	2	1	2/3
3	2.5	1	1/3
4	2.5	1.25	1/6

其中无穷范数是各个绝对值中的最大值。

(c)

对于相邻两步之间的误差比 $\frac{\|V_{k+1} - V^*\|_\infty}{\|V_k - V^*\|_\infty}$ ，我们发现它在上表中严格为 0.5。

这就是 γ -收缩的字面含义，每次迭代误差收缩到原来的 γ 倍。

(d) 初始误差 $\|V_0 - V^*\|_\infty$ 一定满足小于等于 $R_{\max}/(1 - \gamma)$ 。

这是因为：设 $|r| \leq R_{\max}$ ，有折扣回报的上界

$$|G_t| = |r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots| \leq R_{\max} + \gamma R_{\max} + \gamma^2 R_{\max} + \dots = R_{\max}/(1 - \gamma)$$

值函数是折扣回报的期望，则既然每个折扣回报都小于等于这个上界，它们的期望也一定有

$$|V^*(s)| \leq R_{\max}/(1 - \gamma)$$

设初始值函数 V_0 为零向量，则有

$$\|V_0 - V^*\|_{\infty} \leq R_{\max}/(1 - \gamma)$$

得证。

按照压缩映射，

$$\|V_k - V^*\|_{\infty} \leq \gamma \|V_{k-1} - V^*\|_{\infty} \leq \dots \leq \gamma^k \|V_0 - V^*\|_{\infty}$$

假设 $\gamma = 0.9$ ，假设 $R_{\max} = 1$ （其实对于这道题的两个即时奖励应该是 $\max\{2, 0\} = 2$ ，但不重要，能够说明问题就行），则有初始误差 $\leq R_{\max}/(1 - \gamma) = 10$ 。

要使值迭代的误差 $\leq 10^{-2}$ ，则有

$$0.9^k \cdot 10 \leq 10^{-2}$$

解得

$$k \geq \frac{-3 \ln 10}{\ln 0.9} \approx 65.6$$

故至少需要66次迭代，才能把误差降到0.01以下。

(e) γ 的值决定了我们的“有效视野”，即对长期回报的关注度。

定义 $H_{eff} = 1/(1 - \gamma)$ ，则对于各个 γ 值有：

γ	H_{eff}
0.9	10
0.99	100
0.999	1000

γ 每靠近1一个数量级，视野放大10倍。

这个“有效视野”衡量智能体做决策时，大致“往前看多少步”。常用的一种说法是当

$\gamma^t \approx e^{-1} \approx 0.368$ 时，对应的 t 可看作“有效视野”。

近似 $\ln t \approx t - 1$ ，则 $\gamma^t = e^{-1}$ 正对应上述的 $t \approx 1/(1 - \gamma)$ 。于是 H_{eff} 对应的是折扣系数衰减到约37%所需的步数。

1 Bellman方程

考虑一个3状态MDP， $\gamma = 0.5$ ，状态 $\{1, 2, 3\}$ ，每个状态只有一个动作（无控制，直接评估）：

- 状态1：奖励 $R_1 = 2$ ，确定转到状态 2，
- 状态2：奖励 $R_2 = 0$ ，确定转到状态 3，
- 状态3：奖励 $R_3 = 4$ ，确定转到状态 1。

(a) 写出三条Bellman期望方程。

$$V(1) = R_1 + \gamma V(2) = 2 + 0.5V(2)$$

$$V(2) = R_2 + \gamma V(3) = 0 + 0.5V(3)$$

$$V(3) = R_3 + \gamma V(1) = 4 + 0.5V(1)$$

(b) 写成矩阵形式有

$$V = R + \gamma PV$$

其中 $R = (2, 0, 4)^T \in \mathbb{R}^3$ ； $P \in \mathbb{R}^{3 \times 3}$ 满足 $P_{1,2} = 1, P_{2,3} = 1, P_{3,1} = 1$ ，其余项为0。

P 的形式可以通过以下思考得到：

由于

$$(PV)_1 = P_{1,1}V_1 + P_{1,2}V_2 + P_{1,3}V_3$$

（直觉上思考一个 3×3 的矩阵乘以一个 $\mathbb{R}^3$ 的向量，取前者的行、和后者进行点积）
我们为了让这个乘出来的结果为 $V_2 = V(2)$ ，则应该只取中间那个项（系数为1），其余为0。

设 $V = (V(1), V(2), V(3))^T$ ，此时有 $PV = (V(2), V(3), V(1))^T$ 。

(c) 解线性方程组有

$$(I - \gamma P)V = R$$

解得 $V(1) = \frac{24}{7}, V(2) = \frac{20}{7}, V(3) = \frac{40}{7}$ 。

(d) 直接展开求前6项的部分和有

$$V(1) = 2 + 0.5 \times 0 + 0.25 \times 4 + 0.125 \times 2 + 0.0625 \times 0 + 0.03125 \times 4 = 3.375$$

又 $\frac{24}{7} \approx 3.428571$ ，误差约为 0.053571，小于误差上界 $\gamma^6 \cdot R_{max}/(1 - \gamma) = 0.125$ 。