

edit time: 2026-06-08 00:22:44 PPO, RLHF的PPO, DPO

edit time: 2026-06-08 12:20:33 IPO, KTO, GRPO, 收敛性分析

所有主流PO方法都是在优化KL正则化的目标，只是 Quality 的定义不同：

$$\max_{\pi} \mathbb{E}[\text{Quality}(\pi)] - \beta D_{KL}(\pi \parallel \pi_{\text{ref}})$$

方法	Quality 定义	数据类型
RLHF-PPO	$\mathbb{E}_{y \sim \pi}[R(y)]$	奖励模型
DPO	$\mathbb{E}[\log P(y_w \succ y_l)]$ （隐式）	成对偏好
IPO	$\mathbb{E}[(R(y_w) - R(y_l) - m)^2]^{-1}$ （隐式）	成对偏好
KTO	$\mathbb{E}[\text{sign}(y) \cdot \log \pi(y)]$ （近似）	单点标注
GRPO	$\mathbb{E}[\text{rank}(y) \cdot \log \pi(y)]$ （近似）	群体采样

所有 KL 正则化目标的最优策略都有形式：

$$\pi^*(y|x) \propto \pi_{\text{ref}}(y|x) \cdot f(y, x)$$

即所有PO方法都是在对同一个先验 π_{ref} 做指数倾斜 $\pi^* \propto \pi_{ref} e^{g/\beta}$ ，区别仅仅在于用什么能量/质量信号 $g(y)$ 。

PPO-Penalty和PPO-Clip

PPO-Penalty目标

$$L^{KL PEN}(\theta) = \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)} A^{\pi_{\theta_{old}}} - \beta \cdot D_{KL}(\pi_{\theta_{old}}(\cdot|s) \parallel \pi_{\theta}(\cdot|s)) \right]$$

KL PEN大概是KL Penalty的意思罢（无慈悲
设TRPO的KL约束为 δ ，则最优 β^* 满足

$$\beta^* = \frac{1}{\alpha} = \sqrt{\frac{\nabla_{\theta} L^{CPI}(\theta^*)^T F^{-1} \nabla_{\theta} L^{CPI}(\theta^*)}{2\delta}}$$

其中 F 是Fisher矩阵， α 是TRPO的最优步长。

PPO-Clip目标

$$L^{CLIP}(\theta) = \mathbb{E}[\min(r(\theta)A, \text{clip}(r(\theta), 1 - \epsilon, 1 + \epsilon)A)]$$

其中 $r(\theta) = \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)}$ 是重要性比率， ϵ 通常取0.1或0.2。

clipping与KL约束的关系：若 $r(\theta) \in [1 - \epsilon, 1 + \epsilon]$ 对所有 (s, a) 成立，则

$$D_{KL}(\pi_{old}||\pi_{\theta}) \leq \frac{\epsilon^2}{2(1 - \epsilon)}$$

常用的 $\epsilon = 0.2$ 对应KL上界约为 0.025。

PPO-Clip的梯度：

$$\nabla_{\theta} L^{CLIP} = \mathbb{E}[r(\theta)A \cdot \nabla_{\theta} \log \pi_{\theta}(a|s) \cdot \mathbf{1}[r \in \text{active region}]]$$

在 $\theta = \theta_{old}$ 时退化为 $A \nabla_{\theta} \log \pi_{\theta}$ 。

其中，active region 是clip不起作用的区域，即 $r(\theta) \in (-\infty, 1 - \epsilon) \cup (1 + \epsilon, \infty)$ 。

直觉上，在clip范围之外的那些比例，对梯度影响为0。

RLHF中的PPO

RLHF目标为

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot|x)}[R(x, y)] - \beta D_{KL}(\pi_{\theta}||\pi_{ref})$$

其中 π_{ref} 是预训练模型。KL惩罚保持模型不偏离预训练太远，降低Reward Hacking问题。

KL正则化RLHF目标的最优策略 π^* 闭式解为：

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{ref}(y|x) \exp\left(\frac{R(x, y)}{\beta}\right)$$

即最优策略等于：参考模型乘以奖励的指数加权，再归一化。“ **π 乘e的R比 β** ”

模型不是一味追高奖励，而是"在参考模型附近"移动——奖励高的回答概率上升、低的下降，KL惩罚拦着它别偏离原模型太远（ β 越大越保守）。

碎碎念：

这个形式看起来像是将 π_{ref} 对 R 进行了一个Softmax加权，所以 β 起到一个温度的作用。

- 温度趋于 0 时，KL弱约束， π^* 退化为只做reward最高的回答（贪婪策略）；
- 温度趋于 ∞ 时，KL强约束， π^* 退化到先验预训练模型策略 π_{ref} 。

其中分母这个归一化因子称为配分函数

$$Z(x) = \sum_y \pi_{ref}(y|x) \exp\left(\frac{R(x, y)}{\beta}\right)$$

它需要对所有的可能回答 y 求和，但语言模型的回答空间过大、无法枚举。所以不考虑直接对闭式解的计算，而是以闭式解为指导，延伸出：

- 传统RLHF（先学奖励，再用PPO近似优化该目标）
 - DPO/IPO/KTO/ORPO（利用闭式解把奖励消掉，直接从偏好数据训练策略）
- 这两大流派。

RLHF闭式解通过固定 x ，优化RLHF目标（设 $\sum_y \pi(y) = 1$ ）即Lagrangian得到：

$$\mathcal{L} = \sum_y \pi(y) R(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{ref}(y)} + \lambda (1 - \sum_y \pi(y))$$

解法为对 $\pi(y)$ 求导。

当然也可以从 π^* 反解出奖励：

$$R(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

这个式子说，拿到对齐后的 π^* 就能读出奖励， $\log \frac{\pi^*}{\pi_{ref}}$ 正是对齐把回答 y 相对预训练先验抬高/降低了多少，而不必单独训练Reward Model，对应DPO。

与此同时， $\beta \log Z(x)$ 只依赖 x 而不依赖 y ，这意味着奖励的绝对值没有意义，只有同一prompt内的奖励差有意义，这也对应着 $\log Z$ 在DPO中必然抵消。

eg1. 验证一下温度 β 对RLHF最优解的奖励和先验模型的权衡，以及抬高/降低作用。

温度趋于0时，“温度太低，不鼓励创新和活泼”，模型趋于贪婪；

温度趋于无穷时，“温度太高，模型回归原始野性”(bushi。

假设prompt x = "Explain quantum physics"，三个候选回答及其奖励为：

回答	$R(x, y)$	$\pi_{ref}(y x)$
y_1 : "It's complicated."	0.2	0.5
y_2 : "Quantum physics studies..." (中等长度)	0.8	0.3
y_3 : "Quantum physics is..." (详细解释)	1.0	0.2

计算例如 $\beta = 1$ 时，

$$\pi^*(y_1) \propto 0.5 \times e^{0.2/1} \approx 0.611$$

$$\pi^*(y_2) \propto 0.3 \times e^{0.8/1} \approx 0.668$$

$$\pi^*(y_3) \propto 0.2 \times e^{1.0/1} \approx 0.544$$

归一化因子 $Z = 0.611 + 0.668 + 0.544 = 1.823$ ，之后归一化处理后得到

$$\pi^*(y_1) = 0.335, \pi^*(y_2) = 0.366, \pi^*(y_3) = 0.298$$

对这个 $\beta = 1$ 的例子，顺手从最优策略 π^* 反推一下奖励 R 可以得到：

$$R(y_1) = 1 \times \log \frac{0.335}{0.5} + \log 1.823 = 0.200$$

相同流程有 $R(y_2) \approx 0.800, R(y_3) \approx 1.000$ 。

这也符合DPO能工作的原因：从 π^*/π_{ref} 可以恢复奖励 R 。

同理对于五组 β (0, 0.5, 1.0, 2.0, ∞)，可以解得以下的总结表：

β	$\pi^*(y_1)$	$\pi^*(y_2)$	$\pi^*(y_3)$	$D_{KL}(\pi^* \pi_{ref})$
π_{ref}	0.500	0.300	0.200	0
2.0	0.415	0.337	0.248	0.016
1.0	0.335	0.366	0.298	0.057
0.5	0.201	0.401	0.398	0.201
$\rightarrow 0$	0	0	1	∞

可以由总结表看到，

β 足够大时，KL约束足够小，最优解分布完全与预训练分布 π_{ref} 相同；

β 较小时，最优解分布更倾向于刷高奖励，甚至于贪婪地只取最高奖励回答。

DPO

Bradley-Terry偏好模型 给定两个回答 y_w (winning) 和 y_l (losing)，偏好概率为

$$P(y_w \succ y_l | x) = \sigma(R(x, y_w) - R(x, y_l))$$

其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ 是sigmoid函数。

"偏好概率是奖励差取sigmoid"，这只是“奖励差越大，偏好越确定”的一个建模方式。

DPO目标的推导：

将RLHF最优策略的奖励表示 R 代入Bradley-Terry模型，得到DPO目标。具体而言，

$$R(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

代入Bradley-Terry模型得

$$\begin{aligned} P(y_w \succ y_l) &= \sigma(R(y_w) - R(y_l)) \\ &= \sigma\left(\beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)}\right) \end{aligned}$$

“beta乘log pi比pi 的差值再取sigmoid”

关键观察：RLHF最优策略中仍然存在的 $\log Z$ 抵消了，也就是说这个概率只通过奖励的“相对值”而不是绝对值建模。谁奖励相对更高，相应地偏好概率也更高。这让DPO可以直接优化。

接下来我们用 π_θ 代替 π^* 得到概率 $P_\theta(y_w \succ y_l)$ 。

当我们固定单个偏好对数据 (x, y_w, y_l) 时，可以把概率式子看作关于 θ 的似然函数：

$$L(\theta) = P_\theta(y_w \succ y_l)$$

（设随机变量 X 有概率密度函数 $f(x; \theta)$ ，
概率是 $P(X = x|\theta) = f(x; \theta)$ ，是关于 x 的函数、 θ 已知；
似是 $L(\theta|x) = f(x; \theta)$ ，看作关于 θ 的函数、 x 已知。
似然：已知数据，反过来评价哪个参数更可能产生这个数据”）

从而我们想最大化所有偏好对的对数似然：

$$\max_{\theta} \sum_{(x, y_w, y_l)} \log P_\theta(y_w \succ y_l)$$

这也等价于最小化负对数似然。

当然，求和和期望是等价的（mini-batch近似期望），所以我们得到下述**DPO目标**

$$\mathcal{L}_{DPO}(\theta) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\log \sigma\left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{ref}(y_l|x)}\right) \right]$$

接下来推导一下单个偏好对的DPO梯度（整个数据集的DPO梯度是再取一个mini-batch）。
设

$$\begin{aligned} u &= \beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)} \\ \mathcal{L} &= -\log \sigma(u) \end{aligned}$$

考虑到 σ 的导数

$$\sigma'(u) = \sigma(u)(1 - \sigma(u))$$

(顺便说一下，有恒等式： $\sigma(-u) = 1 - \sigma(u)$ ，即sigmoid函数关于 $(0, 0.5)$ 中心对称)
则有 $-\log \sigma$ 的导数

$$\frac{d}{du}(-\log \sigma(u)) = -\frac{\sigma'(u)}{\sigma(u)} = -(1 - \sigma(u))$$

考虑到 u 对 θ 的梯度

$$\nabla_{\theta} u = \beta \nabla_{\theta} \log \pi_{\theta}(y_w) - \beta \nabla_{\theta} \log \pi_{\theta}(y_l)$$

故有单个偏好对的损失 $\mathcal{L}$ 对 θ 的梯度

$$\nabla_{\theta} \mathcal{L} = -\beta(1 - \sigma(u))(\nabla_{\theta} \log \pi_{\theta}(y_w) - \nabla_{\theta} \log \pi_{\theta}(y_l))$$

我们发现“梯度系数 $\beta(1 - \sigma(u))$ ”有：

单个偏好对的损失取值 $1 - \sigma(u)$ ，正是当前模型预测错误的概率。

预测越错（正确的减去错误的得到的 u 越小），梯度越大。

梯度方向倾向于增加 y_w 的概率、减小 y_l 的概率。

可以证明，DPO的全局最优等于RLHF的最优：

若偏好数据由真实奖励 R^* 和Bradley-Terry模型生成，且 π_{θ} 有足够表达能力，则DPO的全局最优 π_{θ}^* 等于RLHF 的最优策略。证明如下：

在期望意义下（对所有偏好对），最优条件是

$$\sigma(u_{\theta}) = P^*(y_w \succ y_l), \text{对所有}(y_w, y_l)$$

把Bradley-Terry模型： $P^* = \sigma(R^*(y_w) - R^*(y_l))$ 以及 u_{θ} 的定义代入上式，则有

$$\sigma \left(\beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)} \right) = \sigma(R^*(y_w) - R^*(y_l))$$

由于 σ 严格单调，去掉 σ 得

$$\beta \log \frac{\pi^*(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi^*(y_l)}{\pi_{ref}(y_l)} = R^*(y_w) - R^*(y_l)$$

这是一个经典的可加性条件，它意味着存在某个常数 c ，使得

$$\beta \log \frac{\pi_{\theta}(y)}{\pi_{ref}(y)} = R^*(y) + c, \forall y$$

这是因为：记 $f(y) = \beta \log \frac{\pi_{\theta}(y)}{\pi_{ref}(y)}$ ，则条件变形即 $f(y_w) - R^*(y_w) = f(y_l) - R^*(y_l)$ 。这个式子对任意的 y_w 和 y_l 都成立，所以这个差值是一个常数 c （比如固定 y_l 、则对任意 y_w 都有左边等于右边固定的常数，所以左边应该是一个不依赖于 y_w 的常数，与 y_w 无关；同理有右边与 y_l 无关，所以是常数 c ），从而有 $f(y) = R^*(y) + c$ 即上式。

从该式容易推得

$$\pi_{\theta}(y) \propto \pi_{ref}(y) e^{R^*(y)/\beta}$$

这正是RLHF的最优策略形式。

顺便补充一个用于eg2数值计算分析的小的二级结论。对于这里的 $\nabla_{\theta} \log \pi_{\theta}(y_w)$ 和 $\nabla_{\theta} \log \pi_{\theta}(y_l)$ （像上一节的策略梯度），有简单计算方法：假设

$$\pi_{\theta}(y|x) = \text{softmax}(h_{\theta}(x))_y = \frac{\exp(\phi_{\theta}(x, y))}{\sum_{y'} \exp(\phi_{\theta}(x, y'))}$$

对于单个样本 y ，固定 x ，有

$$\log \pi_{\theta}(y) = \phi_{\theta}(y) - \log \sum_{y'} \exp(\phi_{\theta}(y'))$$

对 θ 求梯度，有

$$\nabla_{\theta} \log \pi_{\theta}(y) = \nabla_{\theta} \phi_{\theta}(y) - \frac{\sum_{y'} \exp(\phi_{\theta}(y')) \nabla_{\theta} \phi_{\theta}(y')}{\sum_{y''} \exp(\phi_{\theta}(y''))}$$

注意到 $\pi_{\theta}(y') = \text{softmax}(h_{\theta}(y'))$ （分母求和用的是 y'' 没关系），则有梯度应为

$$\nabla_{\theta} \log \pi_{\theta}(y) = \nabla_{\theta} \phi_{\theta}(y) - \sum_{y'} \pi_{\theta}(y') \nabla_{\theta} \phi_{\theta}(y')$$

这正是期望形式

$$\nabla_{\theta} \log \pi_{\theta}(y) = \nabla_{\theta} \phi_{\theta}(y) - \mathbb{E}_{y' \sim \pi_{\theta}}[\nabla_{\theta} \phi_{\theta}(y')]$$

对于线性参数化的特例，有 $\phi_{\theta}(y) = \theta^T \psi(y)$ ，此时有 $\nabla_{\theta} \phi_{\theta}(y) = \psi(y)$ 。

假设 $\psi(y_w)$ 记作 e_w （代表“赢家特征”）， $\mathbb{E}_{y' \sim \pi_{\theta}}[\nabla_{\theta} \phi_{\theta}(y')]$ 记作 π （代表“平均特征”），则有

$$\nabla_{\theta} \log \pi_{\theta}(y_w) = e_w - \pi$$

同理有 $\nabla_{\theta} \log \pi_{\theta}(y_l) = e_l - \pi$ 。

这个小结论就像是在说， $\log \pi$ 的梯度值，是赢家那一项为1，减去平均策略。

eg2. 假设有Softmax策略，3个token： y_w, y_l, y_{other} ， $\pi_{\theta}(y) = \frac{e^{\theta_y}}{\sum_z e^{\theta_z}}$ ，参数 $\theta = (\theta_w, \theta_l, \theta_o)$ ，初始 $\theta^{(0)} = (0, 0, 0)$ ， $\pi_{\theta}^{(0)} = (1/3, 1/3, 1/3)$ ， $\pi_{ref} = (1/3, 1/3, 1/3)$ ， $\beta = 1$ ，学习率

$\alpha = 0.5$ ，尝试对单个偏好对执行完整的DPO训练过程。

解：直觉上， h_w 就是 y_w 的 $\log \frac{\pi}{\pi_{ref}}$ ， u 是 $\beta(h_w - h_l)$ ， $\mathcal{L}$ 是 $-\log \sigma(u)$ 。

初始loss：

$$h_w = \log \frac{\pi_{\theta}(y_w)}{\pi_{ref}(y_w)} = \log \frac{1/3}{1/3} = 0$$

同理有 $h_l = 0$ 。则有 $u = \beta(h_w - h_l) = 0$, $\mathcal{L} = -\log \sigma(0) = 0.693$ 。

梯度：（我们上述的二级小结论）

$$\nabla_{\theta} \log \pi_{\theta}(y_w) = e_w - \pi_{\theta}^{(0)} = (1, 0, 0) - (1/3, 1/3, 1/3) = (2/3, -1/3, -1/3)$$

$$\nabla_{\theta} \log \pi_{\theta}(y_l) = e_l - \pi_{\theta}^{(0)} = (0, 1, 0) - (1/3, 1/3, 1/3) = (-1/3, 2/3, -1/3)$$

$$\nabla_{\theta} u = \beta(\nabla_{\theta} \log \pi_{\theta}(y_w) - \nabla_{\theta} \log \pi_{\theta}(y_l)) = (1, -1, 0)$$

$$\nabla_{\theta} \mathcal{L} = -(1 - \sigma(0)) \cdot (1, -1, 0) = (-0.5, 0.5, 0)$$

更新参数：

$$\theta^{(1)} = \theta^{(0)} - \alpha \nabla_{\theta} \mathcal{L} = (0, 0, 0) - 0.5 \times (-0.5, 0.5, 0) = (0.25, -0.25, 0)$$

新策略：

$$Z = e^{0.25} + e^{-0.25} + e^0 = 3.063$$

$$\pi^{(1)} = (1.284, 0.779, 1)/3.063 = (0.419, 0.254, 0.327)$$

新loss：

$$h_w = \log \frac{0.419}{1/3} = 0.229, \quad h_l = \log \frac{0.254}{1/3} = -0.272, \quad u = 1 \times (0.229 - (-0.272)) = 0.501,$$

$$\mathcal{L}^{(1)} = -\log \sigma(0.501) = 0.474$$

把上述数值整理为表格：

迭代	$\pi(y_w)$	$\pi(y_l)$	$\pi(y_o)$	u	Loss
0	0.333	0.333	0.333	0	0.693
1	0.419	0.254	0.327	0.501	0.474

继续迭代到收敛，会发现 θ_w 慢慢增大、 θ_l 慢慢减小，以相反方向增长，而与偏好无关的 θ_o 保持为0。极限情况下 $\pi(y_w) \rightarrow 1$ ， $\pi(y_l) \rightarrow 0$ ，但收敛变慢（梯度趋于0）。

IPO和KTO

IPO只是一个DPO的补丁，效果也未必比DPO更好，简单介绍一下。

DPO 假设Bradley-Terry 模型完美成立。但实际中：

- 人类偏好有噪声
- 偏好可能不传递 ($A \succ B$ 且 $B \succ C$ 但 $A \not\succ C$)
- 极端奖励差会导致数值问题

IPO 的想法：用更鲁棒的损失函数。

IPO的目标是：

$$\mathcal{L}_{\text{IPO}}(\theta) = \mathbb{E} \left[\left(\log \frac{\pi_{\theta}(y_w)}{\pi_{\text{ref}}(y_w)} - \log \frac{\pi_{\theta}(y_l)}{\pi_{\text{ref}}(y_l)} - \frac{1}{2\beta} \right)^2 \right]$$


KTO将DPO/IPO的偏好“对”，放松到只需要单独标注的数据（pointwise）。从而可以只有点赞或点踩的数据。

KTO基于前景理论中的“损失厌恶”思想。

KTO的目标是：

$$\mathcal{L}_{\text{KTO}}(\theta) = \mathbb{E}_{x,y} \left[w(y) \cdot \left(1 - v \left(\beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)} - z_{\text{ref}} \right) \right) \right]$$

GRPO



Extended Data Fig. 2 | Illustration of the proposed GRPO for RL-based training. In the proposed framework, a LLM is used as a policy model to generate responses $\{o_1, o_2, \dots, o_G\}$ conditioned on a given query q . Each response within the group is evaluated by a reward model—either learned (model-based) or manually specified (rule-based)—to assign a scalar reward signal. Subsequently, GRPO computes the relative advantages of each group member based on their assigned rewards. Rather than relying on an explicit value function, as in PPO,

GRPO directly estimates advantages from the intra-group reward distribution. The policy parameters are then updated to maximize the expected reward while simultaneously minimizing divergence from a reference policy, typically quantified through the KL divergence. By eliminating the need for a separate value network, GRPO offers a simplified yet effective alternative to traditional actor-critic methods such as PPO.

这个要重点一些。

就像DPO一样，我们希望干掉critic模型 $V(s)$ ，这样大模型能用少得多的成本进行训练。于是，GRPO用组内相对奖励代替critic。

对每个prompt x ，采样 G 个回答 $\{y_1, \dots, y_G\}$ ，计算标准化优势估计：

$$\hat{A}_i = \frac{R(x, y_i) - \bar{R}}{\sigma_R}$$

其中奖励平均 $\bar{R} = \frac{1}{G} \sum_j R(x, y_j)$ ，标准差 $\sigma_R = \sqrt{\frac{1}{G} \sum_j (R(x, y_j) - \bar{R})^2}$ 。

则GRPO的目标为：

$$\mathcal{L}_{GRPO}(\theta) = -\mathbb{E}_{x, \{y_i\}} \left[\frac{1}{G} \sum_{i=1}^G \min \left(r_i \hat{A}_i, \text{clip}(r_i, 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) \right]$$

可以证明，**GRPO的优势估计是无偏的**：设 $R(x, y)$ 的期望为 μ ，可以证明 $\mathbb{E}[\hat{A}_i] = 0$ ，即标准化后的相对优势期望为零，像真正的优势函数一样。证明如下：

$$\mathbb{E}[\hat{A}_i] = \mathbb{E} \left[\frac{R_i - \bar{R}}{\sigma_R} \right] = \mathbb{E} \left[\frac{R_i - \frac{1}{G} \sum_j R_j}{\sigma_R} \right] = \mathbb{E} \left[\frac{R_i}{\sigma_R} \right] - \frac{1}{G} \sum_j \mathbb{E} \left[\frac{R_j}{\sigma_R} \right]$$

由于 R_i 和 R_j 同分布， $\mathbb{E} \left[\frac{R_i}{\sigma_R} \right] = \mathbb{E} \left[\frac{R_j}{\sigma_R} \right]$ 。故有 $\mathbb{E}[\hat{A}_i] = 0$ 得证。

eg3. 一个简单的数值例子

Prompt x: "Write a poem about AI"，采样 $G = 4$ 个回答，奖励： $R = [0.8, 0.6, 0.9, 0.5]$ ，尝试计算一下GRPO的优势估计。

$$\bar{R} = (0.8 + 0.6 + 0.9 + 0.5)/4 = 0.7$$

$$\sigma_R = \sqrt{\frac{1}{4}((0.8 - 0.7)^2 + (0.6 - 0.7)^2 + (0.9 - 0.7)^2 + (0.5 - 0.7)^2)} = \sqrt{0.025} = 0.158$$

标准化优势应为：

$$\hat{A} = (0.8 - 0.7, 0.6 - 0.7, 0.9 - 0.7, 0.5 - 0.7)/0.158 = (0.63, -0.63, 1.26, -1.26)$$

优势估计无偏可以通过把各项加到一起验证： $\sum_i \hat{A}_i = 0$ 。

对于上述的标准化优势，我们可以看到 y_3 最好、 y_4 最差，这和原始奖励的趋势是一致的。

GRPO会增加 y_3 的概率，减小 y_4 的概率。

所以GRPO压根就是直接使用了原始奖励 R ，只是标准化了一下。

顺便补充一些Deepseek V4论文中的讨论。

GRPO只是组内平均——就像是一个模型有多个差的回答，能给那个稍微好一点的回答正反馈——但是PPO有一个Value Model，是不是PPO的上限更高？

以及，GRPO更往前的路在哪里？

我个人没有找到很好的讨论。根据个人的直觉，打分模型更可能左脚踩右脚上天；可是 GRPO 这样更简洁的构造，却更可能稳定、充分地发挥架构的优势。也许这是一个权衡。

但有些事情我们是能够找到证据的。根据论文第5.1节说明：

"Following pre-training, we conducted a post-training phase to yield the final models of DeepSeek-V4 series. Although the training pipeline largely mirrored that of DeepSeek-V3.2, **a critical methodological substitution was made: the mixed Reinforcement Learning (RL) stage was entirely replaced by On-Policy Distillation (OPD;** Gu et al., 2024; Lu and Lab, 2025)."

既然纯粹的 RL pipeline 被替换成了对多个领域首先各自 GRPO 训练专家模型、然后再把它们 OPD 蒸馏到一起，看来是后者能够有更高的提升了。

1. 单专家训练用 GRPO（说明它够用）
2. 多专家融合改用 OPD（说明 GRPO 不适合这个场景）
3. 难验证任务用 GRM（说明 GRPO 依赖的组内比较在难验证任务上可能不够）

收敛性分析

定理 13.1 (PPO 的近似单调改进). 设 ϵ 是 clip 参数, $\delta = \frac{\epsilon}{1-\epsilon}$. 若每次更新满足 $D_{KL}(\pi_{\text{old}} \parallel \pi_{\text{new}}) \leq c\delta^2$ (某常数 c), 则:

$$J(\pi_{\text{new}}) \geq J(\pi_{\text{old}}) - O(\delta^2)$$

即策略改进是近似单调的。

证明思路. Step 1: 回顾 Kakade-Langford 界

$$J(\pi') \geq L_{\pi}(\pi') - C \cdot D_{\text{KL}}^{\max}(\pi \parallel \pi')$$

Step 2: Clip 限制了 KL

由 Clip 机制, $r = \pi'/\pi \in [1 - \epsilon, 1 + \epsilon]$.

单样本 KL: $KL(\pi \parallel \pi') = -\log r \leq \epsilon$ (当 r 接近边界时)

Step 3: 代入得到界

$$J(\pi') \geq L_{\pi}(\pi') - O(\epsilon)$$

由于 $L_{\pi}(\pi') \geq L_{\pi}(\pi) = J(\pi)$ (clip 后的代理目标仍然非负改进), 我们有近似单调性。□

定理 13.2 (DPO 的收敛性——凸优化视角). DPO 损失函数是 θ 的非凸函数, 但在 log-linear 策略参数化下, 有局部收敛保证。

证明思路. Step 1: DPO 损失的 Hessian

$$\mathcal{L} = -\log \sigma(u), \quad \text{其中 } u = \beta(h_w - h_t), \quad h = \log \frac{\pi_\theta}{\pi_{\text{ref}}}$$
$$\nabla_\theta^2 \mathcal{L} = \beta^2 \sigma(u)(1 - \sigma(u))(\nabla_\theta h_w - \nabla_\theta h_t)(\nabla_\theta h_w - \nabla_\theta h_t)^T + \dots$$

Step 2: 局部凸性条件

当 $|u|$ 不太大时 ($\sigma(u)(1 - \sigma(u))$ 远离 0), Hessian 的主项是半正定的。

Step 3: 收敛速率

在局部凸区域, 梯度下降以 $O(1/t)$ 速率收敛。

在非凸区域, 可能收敛到局部最优或鞍点。 $\square$